المندوبية السامية للتخطيط
HAUT-COMMISSARIAT AU PLAN

المدرسة الوطنية للعلوم التطبيقية -أكادير
ⵜⵉⵎⵙⵙⵓⵜ ⵜⵏⴰⵎⵓⵔⵜ ⵏ ⵜⵙⵙⵏⴰⵡⵉⵏ ⵜⵉⵜⵜⴰⵡⵉⵏ- ⴰⴳⴰⴷⵉⵔ.
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES - AGADIR

Rapport du Projet de Fin d'Année

Modélisation de l'impact des taux d'intérêt sur les décisions d'investissement

Présenté par :

EL IDRISSI Salma

EZZAITOUNI Aya

Encadrant à l'ENSAA :

M. TAARABTI Said

Encadrante à l'entreprise :

Mme. BOUZGRARA Khadija

Soutenu le : 18/06/2025, devant la commission du jury :

Encadrant : M. TAARABTI Said

Membre du jury : Mme. LAKHNATI Ghizlane

Membre du jury : M. EL OUAFA Idriss

Filière : Finance et Ingénierie Décisionnelle

Année universitaire : 2025–2026

Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude et mes sincères remerciements à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet de fin d'année portant sur « La modélisation de l'impact du taux d'intérêt sur l'investissement au Maroc ».

Je tiens tout d'abord à remercier tout particulièrement mon encadrant pédagogique, Pr. TAARABTI Said, pour sa disponibilité, ses conseils précieux et la pertinence de ses orientations qui m'ont permis de mener à bien cette étude économétrique.

Mes remerciements s'adressent avec une profonde reconnaissance aux membres de la commission du jury qui ont accepté d'évaluer ce travail. C'est pour moi un honneur de présenter mes résultats devant leur expertise, et je les remercie par avance pour l'intérêt qu'ils porteront à cette étude ainsi que pour leurs futures suggestions.

Je souhaite également exprimer ma gratitude à l'ensemble des professeurs de la filière Finance et Ingénierie Décisionnelle (FID). Leurs enseignements rigoureux et leur accompagnement durant ce cycle d'ingénieur ont été fondamentaux pour acquérir les compétences nécessaires à l'élaboration de ce projet.

Je tiens à exprimer ma reconnaissance envers le Haut-Commissariat au Plan (HCP) pour m'avoir accueillie au sein de ses structures. Je remercie mon maître de stage Mme. BOUZGRARA Khadija pour son accompagnement technique, ainsi que l'ensemble du personnel pour avoir mis à ma disposition les données nécessaires à l'analyse de la conjoncture économique marocaine.

Résumé

Dans le cadre de ce projet, nous avons développé une approche de prévision de la Formation Brute de Capital (FBC) en combinant des méthodes économétriques et des techniques avancées de machine learning. L'étude s'est appuyée sur la mise en œuvre d'un modèle à correction d'erreur vectoriel (VECM) pour l'analyse des relations de long terme entre les variables économiques, ainsi que sur des algorithmes d'apprentissage supervisé tels que Random Forest et XGBoost pour la modélisation et la prévision des séries étudiées.
Une analyse comparative a été réalisée afin d'évaluer les performances des différentes approches de prévision à l'aide de métriques adaptées. Les modèles développés ont ensuite été utilisés pour générer des projections futures de la FBC. Enfin, une interface graphique interactive a été conçue pour centraliser les différentes fonctionnalités du projet .

Mots-clés : Investissement, FBC, VECM, Machine Learning, Random Forest, XGBoost, Prévision des séries temporelles, Analyse économétrique, Interface graphique.

Abstract

As part of this project, we developed a forecasting framework for Gross Capital Formation (GCF) by combining econometric methods with advanced machine learning techniques. The study relied on the implementation of a Vector Error Correction Model (VECM) to analyze long-run relationships among economic variables, as well as supervised learning algorithms such as Random Forest and XGBoost for modeling and forecasting the studied time series. A comparative analysis was conducted to evaluate the performance of the different forecasting approaches using appropriate evaluation metrics. The developed models were then employed to generate future projections of GFCF. Finally, an interactive graphical interface was designed to integrate the various functionalities of the project.

Keywords : Investment, GCF, VECM, Machine Learning, Random Forest, XGBoost, Time Series Forecasting, Econometric Analysis, Graphical User Interface.

Table des matières

Remerciements **I**

Résumé **II**

Abstract **III**

Liste des figures **VIII**

Liste des tableaux **IX**

Liste des abréviations **X**

Introduction générale **1**

1 Présentation de l'organisme d'accueil et cadre conceptuel de l'étude **3**

1.1 Présentation de l'organisme d'accueil (HCP) 3

1.1.1 Histoire du Haut Commissariat au Plan 3

1.1.2 Organigramme du Haut Commissariat au Plan 4

1.2 L'investissement : cadre conceptuel 5

1.2.1 Définition et caractéristiques de l'investissement 5

1.2.2 Typologie de l'investissement 5

1.2.3 Déterminants de l'investissement 6

1.3 Les taux d'intérêt : concepts et fondements 6

1.3.1 Définition et rôle des taux d'intérêt 6

1.3.2 Typologie des taux d'intérêt 7

1.3.3 Détermination des taux d'intérêt 7

1.4 Relation entre taux d'intérêt et investissement 8

1.5 L'investissement privé au Maroc : rôle et importance 9

1.6 Conclusion 10

2 Cadre théorique **11**

2.1 Définition d'un processus stochastique 11

2.1.1 Définition Mathématique d'une Série Temporelle 11

2.1.2 Les composantes d'une série temporelle 12
2.1.3 Modèles de composition d'une série temporelle 13
2.2 Le concept de Stationnarité et Opérateurs Fondamentaux 14
2.2.1 Définition d'un processus stationnaire au sens strict : la stationnarité forte 14
2.2.2 Stationnarité d'ordre deux ou stationnarité faible 15
2.2.3 Le Bruit Blanc (White Noise) 15
2.2.4 Autocovariance et autocorrélation 16
2.2.5 Les Outils Mathématiques : Opérateurs de Décalage (Retard) et de Différenciation 17
2.3 La Modélisation Univariée : Les Processus AR et MA 20
2.3.1 Les Processus Autorégressifs d'ordre p : $AR(p)$ 20
2.3.2 Les Processus Moyenne Mobile d'ordre q : $MA(q)$ 21
2.3.3 L'extension aux processus mixtes : $ARMA(p, q)$ 21
2.4 Les Tests de Racine Unitaire 21
2.4.1 Le test d'ADF 22
2.4.2 Le test de PP 22
2.5 La Théorie de la Cointégration 23
2.5.1 Définition mathématique de la cointégration 23
2.5.2 Le Test de Cointégration de Johansen 23
2.6 Fondements théoriques du VECM 24
2.6.1 Définition 25
2.6.2 Formule générale 25
2.6.3 Hypothèses du modèle VECM 25
2.6.4 Utilité du modèle VECM 26
2.7 Les tests de diagnostic 26
2.7.1 Test d'autocorrélation des résidus 26
2.7.2 Test de normalité (Jarque-Bera) 27
2.7.3 Test d'hétéroscédasticité des résidus 28
2.7.4 Test de stabilité du modèle 28
2.8 Approches ML pour séries temporelles 29
2.8.1 Principaux modèles ML pour séries temporelles 29
2.8.2 Choix du modèle optimal 30
2.8.3 XGBoost 30
2.8.4 Random Forest 32
2.9 Conclusion 33

3 Etude pratique **34**
3.1 Données et Méthodologie d'Analyse 34

3.1.1 Sources et Collecte des Données 34
3.1.2 Spécification et Nature des Variables 36
3.1.3 Analyse des données 36
3.1.4 Analyse statistique 38
3.2 Processus de modélisation économétrique 40
3.2.1 Les tests de spécification du modèle 40
3.2.2 Estimation du modèle VECM 49
3.2.3 Les tests de diagnostic 50
3.3 Prévisions issues du modèle VECM 52
3.3.1 Analyse des prédictions sur la période de test historique 53
3.3.2 Analyse des Résultats et Performances Comparatives 53
3.3.3 Projections Futures pour l'Année 2026 54
3.4 Approche Comparative par Machine Learning 54
3.4.1 Transformation des Données en Format Supervisé 54
3.4.2 Analyse des prédictions sur la période de test historique 55
3.4.3 Analyse des Résultats et Performances Comparatives 56
3.4.4 Projections Futures pour l'Année 2026 56
3.5 Personnalisation 57
3.6 Conclusion 59

Conclusion générale **60**

Bibliographie **61**

Webographie **62**

Table des figures

1.1 Histoire du HCP 4
1.2 Organigramme du Haut Commissariat au Plan 4

2.1 Schéma de décomposition d'une série chronologique 13
2.2 Simulation d'un Bruit Blanc Gaussien 16
2.3 Stratégie simplifiée des tests de racine unitaire 20

3.1 FBC vs taux débiteur 38
3.2 log_fbc en niveau 41
3.3 log_fbc en 1ère différence 41
3.4 taux debiteur en niveau 41
3.5 taux debiteur en 1ère différence 41
3.6 log_pib en niveau 42
3.7 log_pib en 1ère différence 42
3.8 log_crédit en niveau 42
3.9 log_crédit en 1ère différence 42
3.10 inflation en niveau 43
3.11 inflation en 1ère différence 43
3.12 inflation en 2nd différence 43
3.13 log_fbc en niveau 44
3.14 log_fbc en 1ère différence 44
3.15 taux debiteur en niveau 44
3.16 taux debiteur en 1ère différence 44
3.17 log_pib en niveau 45
3.18 log_pib en 1ère différence 45
3.19 log_crédit en niveau 45
3.20 log_crédit en 1ère différence 45
3.21 inflation en niveau 46
3.22 inflation en 1ère différence 46
3.23 Stabilité du modèle 52
3.24 Configuration et importation 57
3.25 Visualisation des prévisions 57

3.26 Tableau des prévisions 58
3.27 Tableau des métriques 58
3.28 Diagnostic et orientations 58
3.29 Synthèse et exportation 59

Liste des tableaux

3.1 Data utilisée 36
3.2 Data nettoyée 37
3.3 EDA 37
3.4 Critères de sélection de l'ordre des retards VAR 47
3.5 Résultats du test de la trace 47
3.6 Résultats du test Maximum Eigenvalue 48
3.7 Les coefficients de l'estimation VECM 49
3.8 Résultat du test d'autocorrélation 50
3.9 Résultat du test de normalité 51
3.10 Résultat du test d'Hétéroscédasticité 51
3.11 Résultats de la prévision VECM 53
3.12 Résultats des métriques VECM 53
3.13 Projection VECM 2026 54
3.14 Les prédictions sur la période de test 55
3.15 Tableau comparatif des performances 56
3.16 Prévision pour l'année 2026 56

Liste des abréviations

HCP	Haut-Commissariat au Plan
FBC	Formation Brute de Capital
FBCF	Formation Brute de Capital Fixe
PIB	Produit Intérieur Brut
IPC	Indice des Prix à la Consommation
EDA	Exploratory Data Analysis
VECM	Vector Error Correction Model
ADF	Augmented Dickey-Fuller
PP	Phillips-Peron
KPSS	Kwiatkowski-Phillips-Schmidt-Shin
MCO	Moindres Carrés Ordinaires
VAR	Vector Autoregression
AIC	Akaike Information Criterion
SC / BIC	Schwarz / Bayesian Information Criterion
LM	Lagrange Multiplier
TS	Trend Stationary
DS	Difference Stationary
ML	Machine Learning
LSTM	Long Short-Term Memory
GRU	Gated Recurrent Unit
CNN 1D	Convolutional Neural Network en une dimension
XGBoost	Extreme Gradient Boosting
OOB	Out-Of-Bag

Introduction générale

Dans un contexte économique marqué par une forte volatilité des marchés financiers, des mutations structurelles de l'économie mondiale et des ajustements fréquents des politiques monétaires, la compréhension des déterminants de l'investissement constitue un enjeu majeur pour les décideurs publics et privés. En effet, l'investissement représente l'un des principaux moteurs de la croissance économique, de la création d'emplois et du renforcement de la compétitivité d'un pays. Son évolution dépend cependant de plusieurs facteurs macroéconomiques, parmi lesquels les taux d'intérêt occupent une place centrale.

Au Maroc, les décisions de politique monétaire mises en œuvre par Bank Al-Maghrib influencent directement les conditions de financement de l'économie. À travers le mécanisme de transmission monétaire, les variations des taux d'intérêt affectent le coût du crédit, la disponibilité des financements bancaires ainsi que les anticipations des agents économiques, ce qui peut modifier leurs décisions d'investissement. Toutefois, cette relation demeure complexe et dépend également d'autres variables économiques telles que la croissance économique, le niveau du crédit bancaire et l'inflation.

Dans cette perspective, il apparaît essentiel d'étudier les interactions existantes entre ces différents indicateurs afin de mieux comprendre la dynamique de l'investissement au Maroc. L'analyse de ces relations nécessite le recours à des outils quantitatifs capables de prendre en considération les interdépendances entre variables macroéconomiques ainsi que leurs effets à court et à long terme.

La problématique centrale de ce projet peut ainsi être formulée comme suit :

Dans quelle mesure les taux d'intérêt influencent-ils l'investissement au Maroc et quelles approches de modélisation permettent de prévoir efficacement son évolution future ?

Afin d'apporter des éléments de réponse à cette question, ce travail s'appuie sur des données macroéconomiques marocaines relatives à la Formation Brute de Capital (FBC), au taux d'intérêt débiteur, au Produit Intérieur Brut (PIB), au crédit bancaire et à l'in-

flation. Une première approche économétrique basée sur le modèle à correction d'erreur vectoriel (VECM) est mobilisée afin d'identifier les relations d'équilibre de long terme et les mécanismes d'ajustement de court terme entre ces variables. Dans un second temps, des techniques de Machine Learning, notamment Random Forest et XGBoost, sont mises en œuvre dans une optique de prévision et de comparaison des performances avec l'approche économétrique traditionnelle.

L'objectif principal de ce projet est donc de construire un cadre d'analyse et de prévision de l'investissement privé au Maroc en combinant les apports de l'économétrie moderne et de l'intelligence artificielle. Cette démarche vise non seulement à améliorer la compréhension des mécanismes économiques étudiés, mais également à fournir un outil d'aide à la décision susceptible d'accompagner les acteurs économiques dans leurs choix stratégiques.

Pour atteindre ces objectifs, le présent rapport est structuré en trois chapitres. Le premier chapitre présente l'organisme d'accueil ainsi que le cadre conceptuel relatif à l'investissement et aux taux d'intérêt. Le deuxième chapitre expose les fondements théoriques et méthodologiques de l'analyse économétrique et des techniques de Machine Learning utilisées. Enfin, le troisième chapitre est consacré à l'étude empirique, à l'estimation des modèles, à l'analyse des résultats obtenus ainsi qu'à la comparaison des performances prédictives des différentes approches retenues.

Chapitre 1

Présentation de l'organisme d'accueil et cadre conceptuel de l'étude

1.1 Présentation de l'organisme d'accueil (HCP)

Le Haut-Commissariat au Plan (HCP) constitue l'institution nationale chargée de la production, de l'analyse et de la diffusion des statistiques officielles au Maroc. Placé sous l'autorité du Chef du Gouvernement, cet organisme joue un rôle central dans l'élaboration des politiques publiques en fournissant des données fiables, actualisées et pertinentes sur les différentes dimensions économiques, sociales et démographiques du pays.

Créé afin de répondre aux besoins croissants en information statistique, le HCP a pour principales missions la réalisation des recensements, des enquêtes nationales et des études prospectives. Il intervient notamment dans la production des comptes nationaux, l'analyse de la conjoncture économique. À ce titre, il constitue une référence essentielle pour les décideurs publics, les chercheurs et les institutions internationales.

Cette expérience au sein du HCP constitue un apport significatif, tant sur le plan académique que professionnel, en permettant de mobiliser les outils théoriques et économétriques dans un cadre appliqué et en lien direct avec les réalités économiques du Maroc.

1.1.1 Histoire du Haut Commissariat au Plan

L'histoire du Haut-Commissariat au Plan témoigne de sa transformation progressive d'un simple bureau de centralisation des données en un véritable laboratoire d'analyse et d'aide à la décision stratégique pour le Royaume.

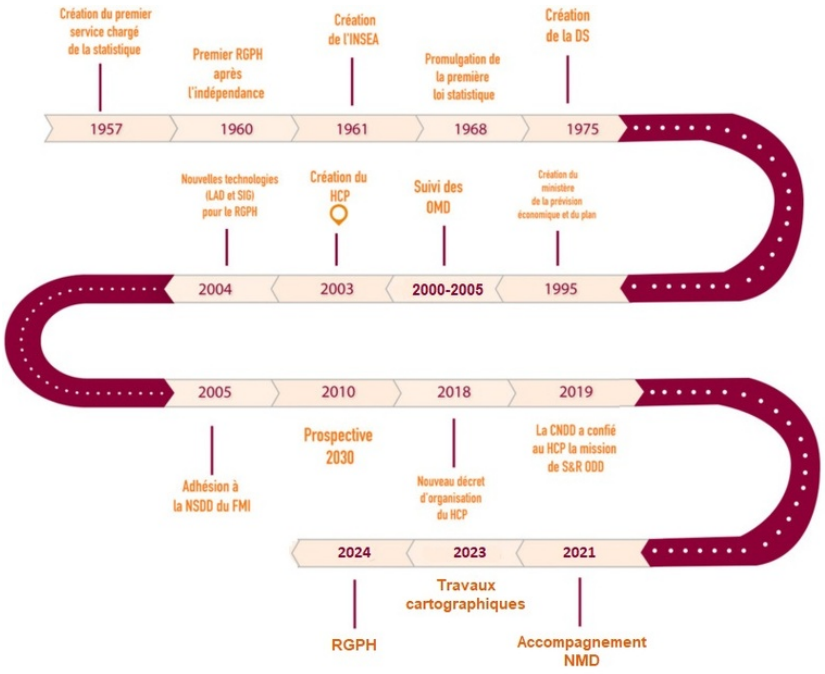


FIGURE 1.1 – Histoire du HCP

1.1.2 Organigramme du Haut Commissariat au Plan

Afin de mener à bien ses missions d'analyse et de prévision, le Haut-Commissariat au Plan s'appuie sur une structure organisationnelle rigoureuse et sectorisée, schématisée par l'organigramme suivant :

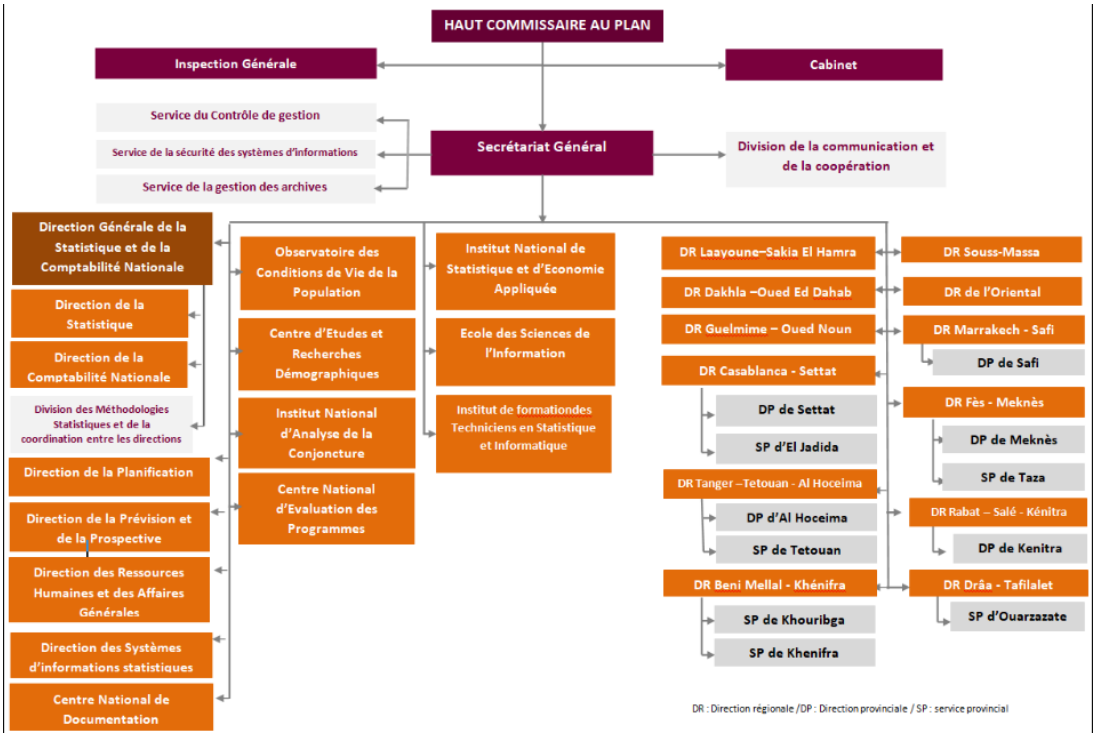


FIGURE 1.2 – Organigramme du Haut Commissariat au Plan

1.2 L'investissement : cadre conceptuel

1.2.1 Définition et caractéristiques de l'investissement

L'investissement désigne, en économie, l'affectation de ressources financières ou matérielles dans des actifs productifs dans le but de générer un rendement futur. En macroéconomie, l'investissement est généralement mesuré par FBCF, qui reflète l'accumulation du capital productif dans une économie. Cette mesure permet ainsi de quantifier les efforts d'investissement réalisés par les entreprises, l'État et les ménages pour accroître le stock de capital du pays.

Il convient de distinguer l'investissement de l'épargne. L'épargne représente la part du revenu non consommée et mise de côté, tandis que l'investissement correspond à l'utilisation de ces ressources pour créer ou acquérir des biens productifs. Autrement dit, l'épargne constitue la source de financement, et l'investissement en est la destination.

L'investissement joue un rôle fondamental dans la croissance économique. En augmentant le stock de capital, il améliore la capacité productive de l'économie, favorise la création d'emplois, stimule l'innovation et renforce la compétitivité. Ainsi, un niveau élevé d'investissement est souvent associé à une croissance soutenue et durable.

1.2.2 Typologie de l'investissement

L'investissement peut se classer selon différents critères, en fonction de sa finalité, de son origine et de sa nature.

Investissement productif : Il s'agit des dépenses réalisées pour accroître la capacité de production d'une entreprise ou d'une économie. Il inclut l'acquisition de machines, d'équipements ou de technologies permettant d'améliorer la productivité et la compétitivité.

Investissement public et privé : L'investissement peut être réalisé par le secteur privé ou par l'État. L'investissement privé est effectué par les entreprises ou les ménages à des fins de profit ou de rendement futur. L'investissement public, quant à lui, est réalisé par l'État pour financer des infrastructures, des services publics ou des projets d'intérêt général.

Investissement matériel et immatériel : L'investissement matériel concerne les actifs physiques tels que les bâtiments, les machines ou les équipements. L'investissement immatériel englobe les actifs non physiques, tels que la recherche et développement, les logiciels, la formation du personnel ou le capital humain, qui contribuent également à la croissance

et à l'innovation.

Ainsi, la typologie de l'investissement permet de comprendre la diversité des formes d'allocation des ressources et leur impact sur la dynamique économique.

1.2.3 Déterminants de l'investissement

Les décisions d'investissement des agents économiques dépendent de plusieurs facteurs économiques et financiers.

Tout d'abord, les taux d'intérêt jouent un rôle déterminant, dans la mesure où ils représentent le coût du financement. Une hausse des taux d'intérêt tend à décourager l'investissement en renchérissant le coût du crédit, tandis qu'une baisse favorise l'accès au financement et stimule les projets d'investissement.

Ensuite, la demande anticipée influence fortement les décisions d'investissement. Les entreprises sont plus enclines à investir lorsqu'elles anticipent une augmentation de la demande pour leurs biens et services, ce qui leur permet d'envisager une rentabilité future plus élevée.

Enfin, l'incertitude économique joue un rôle important dans la prise de décision. En période d'instabilité ou de manque de visibilité, les entreprises tendent à retarder ou à réduire leurs investissements en raison du risque accru.

Ainsi, les décisions d'investissement résultent d'un arbitrage entre plusieurs facteurs, combinant conditions financières, perspectives économiques et niveau de risque.

1.3 Les taux d'intérêt : concepts et fondements

1.3.1 Définition et rôle des taux d'intérêt

Les taux d'intérêt constituent une variable essentielle en économie, définie comme le prix du capital, c'est-à-dire la rémunération versée en contrepartie de la mise à disposition de fonds pour une période donnée. Ils représentent ainsi le coût du financement pour les emprunteurs et le rendement pour les prêteurs.

Dans l'économie, les taux d'intérêt jouent un rôle central en influençant les décisions d'épargne, de consommation et d'investissement. Une hausse des taux tend à encoura-

ger l'épargne et à freiner l'investissement en augmentant le coût du crédit, tandis qu'une baisse favorise l'accès au financement et stimule l'activité économique.

Par ailleurs, les taux d'intérêt constituent un instrument clé de la politique monétaire. À travers la fixation du taux directeur, la banque centrale agit sur les conditions de financement afin de maîtriser l'inflation et soutenir la croissance économique.

Ainsi, les taux d'intérêt participent à la fois à l'allocation des ressources financières et à la régulation de l'activité économique.

1.3.2 Typologie des taux d'intérêt

Le taux d'intérêt se déclinent en plusieurs catégories selon leur nature, leur horizon temporel et leur fonction dans le système financier.

En premier lieu, il convient de distinguer le taux d'intérêt nominal du taux d'intérêt réel. Le taux nominal correspond au taux observé sur le marché, sans prise en compte de l'inflation. En revanche, le taux réel intègre l'effet de l'inflation et reflète ainsi le coût réel du capital pour les agents économiques. Cette distinction est essentielle, car les décisions d'investissement reposent principalement sur les taux réels.

Ensuite, les taux d'intérêt peuvent être classés en taux à court terme et taux à long terme. Les taux à court terme concernent généralement des échéances inférieures à un an et sont fortement influencés par les décisions de la banque centrale. Les taux à long terme, quant à eux, s'appliquent à des horizons plus étendus et intègrent les anticipations des agents économiques en matière d'inflation, de croissance et de risque.

Par ailleurs, on distingue les taux débiteurs des taux créditeurs. Les taux débiteurs sont ceux appliqués aux emprunteurs, représentant le coût du crédit, tandis que les taux créditeurs correspondent à la rémunération offerte aux épargnants pour leurs dépôts.

Enfin, le taux directeur, fixé par la banque centrale, constitue un instrument central de la politique monétaire. Il influence l'ensemble des taux pratiqués sur le marché et permet aux autorités monétaires de réguler la liquidité, de maîtriser l'inflation et de soutenir l'activité économique.

1.3.3 Détermination des taux d'intérêt

La détermination des taux d'intérêt résulte d'un ensemble d'interactions complexes entre les forces économiques et les mécanismes financiers.

De prime abord, les taux d'intérêt sont influencés par l'équilibre entre l'offre et la demande de capitaux. Une augmentation de la demande de financement, notamment de la part des entreprises ou de l'État, exerce une pression à la hausse sur les taux, tandis qu'une abondance de liquidités sur le marché tend à les réduire.

Par ailleurs, la banque centrale joue un rôle fondamental dans la formation des taux d'intérêt, Bank Al-Maghrib agit principalement à travers le taux directeur, qu'elle ajuste en fonction des objectifs de stabilité des prix et de soutien à l'activité économique. Ce taux sert de référence pour l'ensemble des taux pratiqués dans le système bancaire.

L'inflation et les anticipations des agents économiques constituent également des déterminants majeurs. En effet, une inflation élevée ou anticipée conduit généralement à une augmentation des taux d'intérêt, afin de compenser la perte de pouvoir d'achat et de maintenir l'équilibre réel des rendements.

Enfin, les conditions des marchés financiers influencent également les taux d'intérêt. Des éléments tels que le niveau de risque, la stabilité économique, la confiance des investisseurs et les flux de capitaux peuvent affecter leur évolution. En période d'incertitude, les taux ont tendance à augmenter en raison d'une prime de risque plus élevée.

1.4 Relation entre taux d'intérêt et investissement

La relation entre les taux d'intérêt et l'investissement constitue un élément central de l'analyse économique. Elle traduit l'influence des conditions de financement sur les décisions des agents économiques, notamment les entreprises. Cette relation a été abordée par plusieurs courants théoriques.

Approche classique

Dans l'approche classique, l'investissement est déterminé par l'épargne disponible, et le taux d'intérêt joue un rôle d'équilibre entre ces deux grandeurs. En effet, le taux d'intérêt s'ajuste de manière à assurer l'égalité entre l'épargne et l'investissement sur le marché des capitaux. Une hausse du taux d'intérêt encourage l'épargne et réduit l'investissement, tandis qu'une baisse produit l'effet inverse. Ainsi, le taux d'intérêt apparaît comme un mécanisme d'équilibrage entre l'offre et la demande de fonds prêtables.

Approche keynésienne

L'approche keynésienne met l'accent sur le rôle de l'efficacité marginale du capital, c'est-à-dire le rendement attendu des investissements. Les entreprises décident d'investir lorsque ce rendement est supérieur au taux d'intérêt. Toutefois, cette approche souligne également l'importance des anticipations des agents économiques. En période d'incertitude ou de faible confiance, les entreprises peuvent réduire leurs investissements, même en présence de taux d'intérêt bas. Ainsi, la sensibilité de l'investissement aux taux d'intérêt peut être limitée dans certains contextes.

Approche néoclassique

L'approche néoclassique met en avant le rôle du coût du capital dans la décision d'investissement. Ce coût dépend notamment des taux d'intérêt, mais aussi d'autres facteurs tels que la fiscalité et le prix des biens d'équipement. Les entreprises réalisent un arbitrage entre investissement et financement en fonction de ce coût. Lorsque le coût du capital est faible, l'investissement est encouragé, tandis qu'un coût élevé tend à le freiner.

Synthèse théorique

Les différentes approches théoriques convergent vers l'idée que les taux d'intérêt influencent les décisions d'investissement, principalement à travers le coût du financement. Toutefois, elles diffèrent quant à l'intensité et aux mécanismes de cette relation. Alors que l'approche classique met l'accent sur l'équilibre entre épargne et investissement, l'approche keynésienne insiste sur le rôle des anticipations, et l'approche néoclassique sur le coût du capital.

Cependant, ces théories présentent certaines limites, notamment en raison de leur incapacité à prendre en compte pleinement l'incertitude, les imperfections des marchés financiers et les spécificités des économies réelles. Cela justifie le recours à une analyse empirique afin d'évaluer concrètement la relation entre taux d'intérêt et investissement.

1.5 L'investissement privé au Maroc : rôle et importance

L'investissement privé constitue un levier essentiel de la croissance économique au Maroc, en complément de l'action publique. Il reflète la vitalité du secteur entrepreneurial et la capacité du marché à financer des projets productifs dans l'industrie, les services et l'innovation. Au cours des dernières années, il a contribué de manière significative à l'expansion

du PIB, en soutenant la diversification sectorielle et en renforçant la compétitivité nationale. En 2025, la croissance économique a atteint près de 4,9%, et cette dynamique s'est accompagnée d'une création nette d'environ 193000 emplois, ce qui a permis de réduire le taux de chômage national de 13,3% à 13%. Cette évolution illustre l'impact direct de l'investissement privé sur le marché du travail et son rôle dans l'amélioration du pouvoir d'achat des ménages.

Au-delà de sa contribution à la croissance et à l'emploi, l'investissement privé entretient des liens étroits avec d'autres variables macroéconomiques. Il stimule la consommation en générant des revenus, favorise le recours au crédit pour financer les projets, et influence l'inflation en augmentant la capacité de production et en réduisant les tensions sur l'offre. Ainsi, l'investissement privé apparaît non seulement comme une variable autonome, mais aussi comme un facteur d'interaction avec les autres déterminants de la croissance. C'est cette importance stratégique qui justifie son intégration dans notre cadre théorique et qui nous pousse à étudier cette problématique à travers le modèle VECM, afin de mieux comprendre ses effets et ses liens avec la dynamique économique du Maroc.

1.6 Conclusion

Ce premier chapitre a permis de poser le cadre institutionnel de notre étude au sein du HCP, ainsi que le socle théorique nécessaire à la compréhension de notre sujet.

À travers la revue de la littérature, nous avons défini l'investissement et les taux d'intérêt, mettant en lumière le lien d'interdépendance crucial qui existe entre le coût du capital et la dynamique de la FBC. Ce cadre conceptuel nous a également permis d'identifier le PIB et le crédit bancaire comme des déterminants indispensables à l'analyse.

Ce bloc théorique étant désormais solidement établi, il servira de guide pour l'analyse empirique à venir, dont l'objectif sera de quantifier et de modéliser concrètement ces relations pour l'économie marocaine.

Chapitre 2

Cadre théorique

Ce chapitre a pour objectif de présenter les fondements théoriques de l'économétrie ainsi que les principaux outils méthodologiques utilisés dans l'analyse des phénomènes économiques.Il permettra de mettre en évidence les notions essentielles relatives à la modélisation, à l'estimation et à l'interprétation des relations entre les variables, afin de mieux comprendre la démarche économétrique adoptée dans cette étude.

2.1 Définition d'un processus stochastique

Un processus stochastique est une famille de variables aléatoires indexées par le temps $\{X_t,\ t \in T\}$ définies sur un même espace probabilisé $(\Omega, \mathcal{F}, P)$.
L'ensemble T est l'indice du temps (discret : $T = N$ ou Z , ou continu : $T = R^+$).
Pour chaque réalisation $\omega \in \Omega$, la fonction $t \mapsto X_t(\omega)$ est appelée une trajectoire du processus.

2.1.1 Définition Mathématique d'une Série Temporelle

Sur le plan mathématique, une série temporelle est la réalisation d'un processus stochastique. Elle se définit comme une suite discrète de variables aléatoires ordonnées par rapport au temps, notée :

$$\{X_t\}_{t \in T} \quad \text{ou} \quad (X_1, X_2, \ldots, X_T)$$

Où :

— X est la variable aléatoire étudiée.
— t représente l'indice temporel discret (généralement $t = 1, 2, \ldots, T$).
— T correspond à la taille de l'échantillon.

2.1.2 Les composantes d'une série temporelle

Une série temporelle est généralement constituée de plusieurs éléments :

Tendance

La tendance correspond au mouvement de long terme qui traduit l'évolution générale de la série, qu'il s'agisse d'une hausse, d'une baisse ou d'une stabilité, indépendamment des fluctuations de court terme.
La tendance peut prendre différentes formes selon la nature des données :

- **Linéaire :** évolution proportionnelle au temps.
- **Polynomiale :** évolution plus complexe, pouvant inclure des termes quadratiques ou cubiques.
- **Exponentielle :** croissance ou décroissance rapide.
- **Logarithmique :** progression qui ralentit au fur et à mesure.

Ainsi, l'identification et la modélisation de la tendance constituent une étape essentielle dans l'analyse des séries temporelles, car elles permettent de distinguer la dynamique de fond des variations saisonnières ou aléatoires.

Composante périodique, Saisonnalité

On parle de composante périodique, ou de périodicité, lorsque la série se décompose en :

$$X_n = e_n + s_n \quad \text{pour } n = 1, 2, \ldots$$

où s_n est périodique, c'est-à-dire :

$$s_{n+T} = s_n \quad \text{pour tout } n,$$

avec T la période (supposée entière), et où e_n est un résidu non-périodique et sans tendance.

Composante résiduelle

Les variations accidentelles sont des fluctuations irrégulières et imprévisibles. Elles sont supposées en général de faible amplitude. Elles proviennent de circonstances non prévisibles : catastrophes naturelles, crise boursière, grèves ...De ce fait, elle regroupe tout ce qui n'est pas pris en compte par les deux précédentes composantes.

Pour mieux appréhender l'impact de chacun de ces mouvements, la Figure 2.1 présente une illustration graphique de cette décomposition.

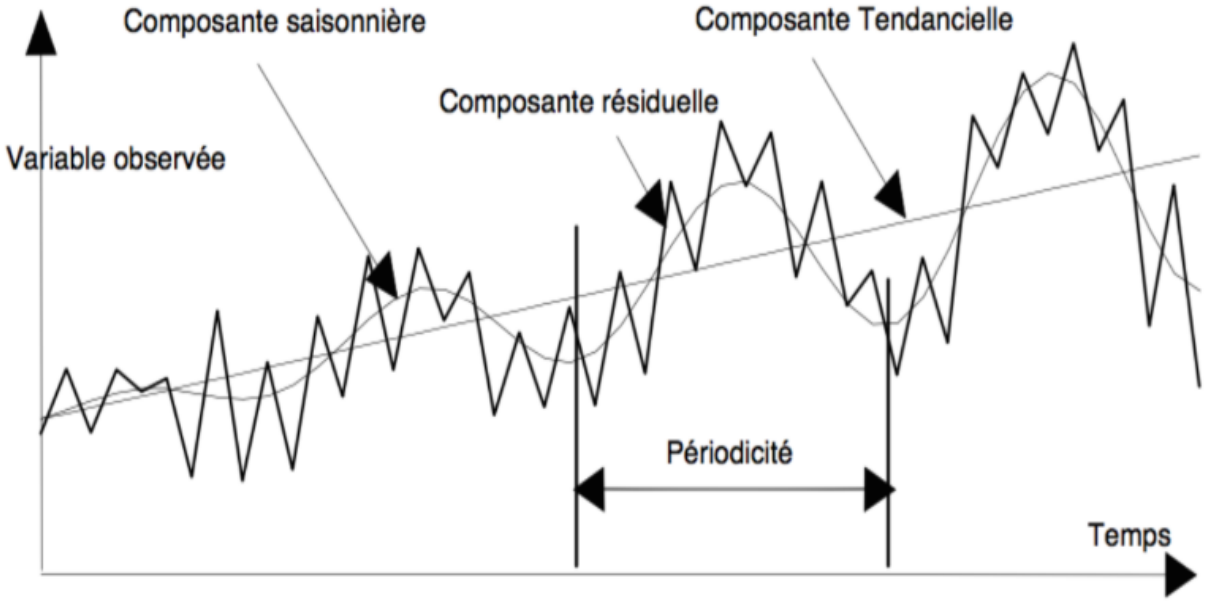


FIGURE 2.1 – Schéma de décomposition d'une série chronologique

2.1.3 Modèles de composition d'une série temporelle

Pour analyser et modéliser une série chronologique, il est nécessaire de spécifier la manière dont ses différentes composantes se combinent. On distingue généralement deux structures de modèles :

— **Modèle additif** : On suppose dans ce modèle que les composantes sont indépendantes les unes des autres. Les variations saisonnières sont constantes d'une année à l'autre, quelle que soit la tendance générale de la série.

Le modèle additif combine une tendance f, une saisonnalité de période p et une composante résiduelle de la manière suivante :

$$y_t = f_t + s_t + \epsilon_t \quad \text{pour } t = 1, \ldots, n \tag{2.1}$$

Afin d'assurer l'identifiabilité des composantes (éviter qu'une constante puisse être transférée d'une composante à l'autre lors de l'estimation), ce modèle impose les deux contraintes théoriques suivantes :

$$\sum_{t=1}^{p} s_t = 0 \quad \text{et} \quad \sum_{t=1}^{n} \epsilon_t = 0 \tag{2.2}$$

La première condition signifie que l'effet de la saisonnalité se compense exactement

sur une période complète p, tandis que la seconde stipule que la somme (et donc la moyenne) des résidus est nulle.

— **Modèle multiplicatif** : On utilise préférentiellement ce modèle lorsque l'amplitude des fluctuations saisonnières évolue proportionnellement au niveau de la tendance. Plus la tendance est haute, plus l'impact de la saisonnalité est marqué.

$$y_t = f_t(1 + s_t)(1 + \epsilon_t) \quad \text{pour } t = 1, \ldots, n \tag{2.3}$$

avec également les contraintes de normalisation suivantes :

$$\sum_{t=1}^{p} s_t = 0 \quad \text{et} \quad \sum_{t=1}^{n} \epsilon_t = 0 \tag{2.4}$$

Dans cette formulation, s_t et ϵ_t s'interprètent comme des écarts relatifs (en pourcentage) par rapport à la tendance f_t. Les conditions de somme nulle garantissent que les fluctuations saisonnières et les perturbations s'annulent en moyenne sur la période d'étude.

2.2 Le concept de Stationnarité et Opérateurs Fondamentaux

Avant le traitement d'une série chronologique, il convient d'en étudier les caractéristiques stochastiques. Si ces caractéristiques (c'est-à-dire son espérance et sa variance) se trouvent modifiées dans le temps, alors la série chronologique est considérée comme non stationnaire. Dans le cas d'un processus stochastique invariant, la série temporelle est alors stationnaire.
Pour pouvoir, à partir d'une seule réalisation, faire de l'inférence sur un processus stochastique, il faut imposer des restrictions à ce dernier. La restriction imposée habituellement est qu'il soit **stationnaire** (au sens faible).

2.2.1 Définition d'un processus stationnaire au sens strict : la stationnarité forte

Soit un processus temporel aléatoire $(X_t,\ \forall t \in Z)$.
Définition : Le processus (X_t) est dit stationnaire au sens fort si la loi de tout vecteur $(X_{t_1}, \ldots, X_{t_n})$ est invariante par translation temporelle :

$$L(X_{t_1}, \ldots, X_{t_n}) = L(X_{t_1+h}, \ldots, X_{t_n+h}), \quad (t_1, \ldots, t_n) \in Z^n,\ \forall h \in Z.$$

2.2.2 Stationnarité d'ordre deux ou stationnarité faible

Dans la pratique, on se limite généralement à requérir la stationnarité du second ordre (ou stationnarité faible) du processus étudié.

Définition 3. Un processus $(X_t,\ \forall t \in Z)$ est dit stationnaire au second ordre, ou stationnaire au sens faible si les trois conditions suivantes sont satisfaites :

- $\forall t \in Z,\ E(X_t^2) < \infty$
- $\forall t \in Z,\ E(X_t) = m \quad$ (indépendant de t)
- $\mathrm{Cov}(X_t, X_{t+h}) = E[(X_{t+h} - m)(X_t - m)] = \gamma(h) \quad$ (indépendant de t)

2.2.3 Le Bruit Blanc (White Noise)

Le concept de bruit blanc est le pilier fondamental de la modélisation des séries temporelles. En théorie des processus stochastiques, il représente l'analogue d'un signal lumineux contenant toutes les fréquences (la lumière blanche). Graphiquement, il se traduit par une suite de fluctuations purement erratiques, sans tendance, sans saisonnalité, ni mémoire.

Définition mathématique : Un processus stochastique ϵ_t est qualifié de bruit blanc faible (ou stationnaire d'ordre 2) . Il vérifie rigoureusement les propriétés suivantes :

$$E(\epsilon_t) = 0 \quad \forall t \in Z \tag{2.5}$$

$$\mathrm{Var}(\epsilon_t) = \sigma^2 \quad \forall t \in Z \tag{2.6}$$

$$\gamma_k = \mathrm{Cov}(\epsilon_t, \epsilon_{t-k}) = \begin{cases} \sigma^2 & \text{si } k = 0 \\ 0 & \text{si } k \neq 0 \end{cases} \tag{2.7}$$

Interprétation théorique des propriétés :

- **Espérance nulle** : Le processus ne subit aucune dérive systématique d'ordre déterministe. Il oscille de manière purement symétrique autour de son niveau moyen.
- **Homoscédasticité** : L'amplitude globale des chocs ou de l'incertitude reste constante et stable tout au long de la période d'étude.
- **Absence d'autocorrélation** : Les valeurs passées du processus n'exercent aucune influence sur sa valeur présente ou future.

Si, en plus de ces trois conditions de second ordre, les variables aléatoires composant la série ϵ_t sont totalement i.i.d selon une loi normale, le processus est alors qualifié de **bruit blanc gaussien** (ou bruit blanc fort), ce que l'on note mathématiquement :

$$\epsilon_t \sim \text{i.i.d. } \mathcal{N}(0, \sigma^2) \tag{2.8}$$

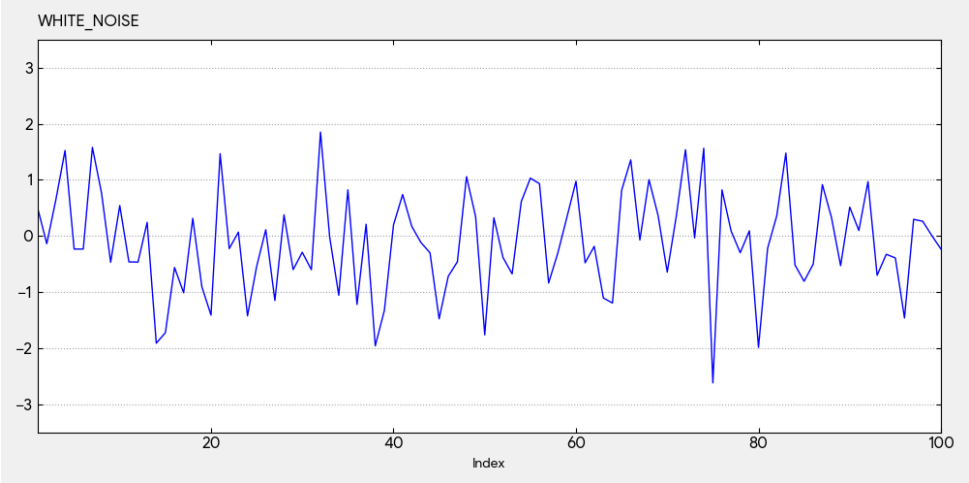


FIGURE 2.2 – Simulation d'un Bruit Blanc Gaussien

2.2.4 Autocovariance et autocorrélation

Définition . Pour une série $(Y_t)_{t\in Z}$, on définit la fonction d'autocovariance, pour tout $t \in Z$ notée γ_k, par :

$$\gamma_k = \text{cov}(Y_t, Y_{t-k}) = E\big[(Y_t - E(Y_t))(Y_{t-k} - E(Y_{t-k}))\big]$$

L'expression de γ_k est estimée par l'autocovariance empirique :

$$\hat{\gamma}_k = \frac{1}{n}\sum_{t=k+1}^{n}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})$$

où $\bar{Y}$ désigne la moyenne de la série calculée sur n périodes.

Définition . Pour une série $(Y_t)_{t\in Z}$, on appelle autocorrélation au retard k l'expression définie par :

$$\rho_k = \frac{\text{cov}(Y_t, Y_{t-k})}{\sqrt{V(Y_t)V(Y_{t-k})}} = \frac{\gamma_k}{\gamma_0}$$

Avec $\gamma_k = \text{cov}(Y_t, Y_{t-k})$ d'autocovariance au retard k.
Si $k = 0$, alors $\gamma_0 = V(Y_t)$ et puisque le processus est stationnaire :

$$V(Y_t) = V(Y_{t-k}) = \gamma_0 = \text{Cte.}$$

Elle représente le lien linéaire entre le présent et le passé d'ordre h.

L'expression de ρ_k est estimée par l'autocorrélation empirique :

$$\hat{\rho}_k = \frac{\sum_{t=k+1}^{n}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^{n}(Y_t - \bar{Y})^2}$$

2.2.5 Les Outils Mathématiques : Opérateurs de Décalage (Retard) et de Différenciation

Pour modéliser la dépendance temporelle d'une série chronologique et formaliser rigoureusement les équations de comportement, la théorie économétrique s'appuie sur l'introduction de deux opérateurs mathématiques fondamentaux.

1. L'opérateur retard (Lag operator)

L'opérateur retard, généralement noté L (ou B pour *Backward shift*), est un opérateur linéaire qui, appliqué à une variable temporelle, permet de la décaler d'une période en arrière dans le passé.

Par définition :

$$Ly_t = y_{t-1} \tag{2.9}$$

Par itération, cet opérateur permet de remonter à un horizon de temps k supérieur :

$$L^2 y_t = L(Ly_t) = Ly_{t-1} = y_{t-2} \quad \text{et plus généralement, } L^k y_t = y_{t-k} \tag{2.10}$$

Les principales propriétés algébriques de cet opérateur sont :

— La linéarité : $L(ax_t + by_t) = ax_{t-1} + by_{t-1}$, où a et b sont des constantes.

— La multiplication par une constante : $Lc = c$.

2. L'opérateur de différenciation première

L'opérateur de différenciation, noté Δ, est utilisé pour calculer les variations absolues d'une série d'une période à l'autre. Il s'exprime très simplement en combinaison avec l'opérateur retard :

$$\Delta y_t = y_t - y_{t-1} = (1 - L)y_t \tag{2.11}$$

D'un point de vue statistique, l'application de cet opérateur Δ permet d'éliminer les tendances linéaires (non-stationnarité en moyenne) afin de stabiliser le comportement d'une série chronologique.

3. L'opérateur de différenciation d'ordre d

Si une série présente une non-stationnarité plus complexe ou plus forte, une seule différenciation peut s'avérer insuffisante. On applique alors le filtre de manière itérative à l'ordre d, noté Δ^d.

Pour une différenciation d'ordre 2, l'expression mathématique devient :

$$\Delta^2 y_t = \Delta(\Delta y_t) = \Delta(y_t - y_{t-1}) = \Delta y_t - \Delta y_{t-1} \tag{2.12}$$

En utilisant l'opérateur retard L, on peut factoriser l'identité de la manière suivante :

$$\Delta^2 y_t = (1-L)^2 y_t = (1 - 2L + L^2) y_t = y_t - 2y_{t-1} + y_{t-2} \tag{2.13}$$

Plus généralement, pour un ordre de différenciation quelconque $d \in N^*$, l'opérateur s'exprime sous sa forme polynomiale générale en vertu de la formule du binôme de Newton :

$$\Delta^d y_t = (1-L)^d y_t = \sum_{k=0}^{d} \binom{d}{k} (-1)^k L^k y_t = \sum_{k=0}^{d} \binom{d}{k} (-1)^k y_{t-k} \tag{2.14}$$

Où $\binom{d}{k} = \frac{d!}{k!(d-k)!}$ représente les coefficients binomiaux.

En pratique, l'opérateur retard L servira de bloc de construction pour définir les polynômes de retards des processus autorégressifs (AR). L'opérateur Δ sera quant à lui la clé permettant de transformer une série économique non stationnaire en une série stationnaire propre à la modélisation.

Les Processus Non Stationnaires : Processus TS vs Processus DS

Dans la pratique économique et financière, la quasi-totalité des séries chronologiques brutes (PIB, taux d'intérêt, cours boursiers) présentent une dynamique non stationnaire. Pour pouvoir appliquer les modèles de type Box-Jenkins, il est crucial d'identifier l'origine de cette non-stationnarité. La littérature économétrique classique distingue deux grandes classes de processus non stationnaires.

1. Les processus TS

Un processus est dit TS lorsque sa non-stationnarité est de nature purement **déterministe**. Cela signifie que la série évolue de manière prévisible autour d'une tendance déterministe temporelle (linéaire, quadratique ou exponentielle).

L'équation théorique d'un processus TS linéaire s'écrit :

$$y_t = \alpha + \beta t + \epsilon_t \tag{2.15}$$

Où t représente la variable temps ($t = 1, 2, \ldots, n$), β est la pente de la tendance déterministe et ϵ_t est un bruit blanc stationnaire.

Méthode de stationnarisation : Comme la tendance est déterministe, la trajectoire de long terme est parfaitement prévisible. Pour rendre la série stationnaire, il suffit d'extraire cette tendance en estimant les paramètres α et β par la méthode des MCO, puis d'étudier le résidu de la régression, qui est par construction stationnaire :

$$\tilde{y}_t = y_t - (\hat{\alpha} + \hat{\beta} t) = \epsilon_t \sim \text{Stationnaire} \tag{2.16}$$

2. Les processus DS

Un processus est dit DS lorsque sa non-stationnarité est de nature stochastique. Dans ce cas, la série intègre la mémoire de tous les chocs passés de manière permanente. Le modèle de référence d'un processus DS est la marche aléatoire.

L'équation théorique d'un processus DS avec dérive s'écrit :

$$y_t = \mu + y_{t-1} + \epsilon_t \quad \Leftrightarrow \quad (1 - L) y_t = \mu + \epsilon_t \tag{2.17}$$

Où μ représente la dérive (le *drift*) et ϵ_t est un bruit blanc. Si on développe cette équation par récurrence à partir d'une condition initiale y_0, on obtient :

$$y_t = y_0 + \mu t + \sum_{i=1}^{t} \epsilon_i \tag{2.18}$$

On constate que la variance de ce processus, $\text{Var}(y_t) = t\sigma^2$, dépend explicitement du temps t et tend vers l'infini lorsque t augmente, ce qui viole la condition de stationnarité. De plus, le terme de sommation $\sum \epsilon_i$ montre que chaque choc subit par le système a un impact permanent sur la trajectoire future (mémoire infinie ou présence d'une **racine unitaire**).

Méthode de stationnarisation : Pour éliminer cette non-stationnarité stochastique, la méthode de l'ajustement par régression temporelle est inefficace. Il faut impérativement appliquer l'opérateur de différenciation première Δ défini précédemment :

$$\Delta y_t = y_t - y_{t-1} = \mu + \epsilon_t \sim \text{Stationnaire} \tag{2.19}$$

3. La notion d'ordre d'intégration $I(d)$

Cette distinction permet d'introduire formellement la notion d'ordre d'intégration d'une série temporelle, définie par Engle et Granger :

Une série chronologique y_t est dite intégrée d'ordre d, notée $y_t \sim I(d)$, si elle est non stationnaire mais qu'en lui appliquant d fois le filtre de différenciation première ($\Delta^d y_t$), elle se transforme en une série stationnaire ne comportant plus aucune racine unitaire.

Par extension, une série initialement stationnaire en niveau est dite intégrée d'ordre 0, notée $I(0)$. La majorité des séries macroéconomiques courantes sont de nature $I(1)$, nécessitant une seule différenciation pour être stationnarisées.

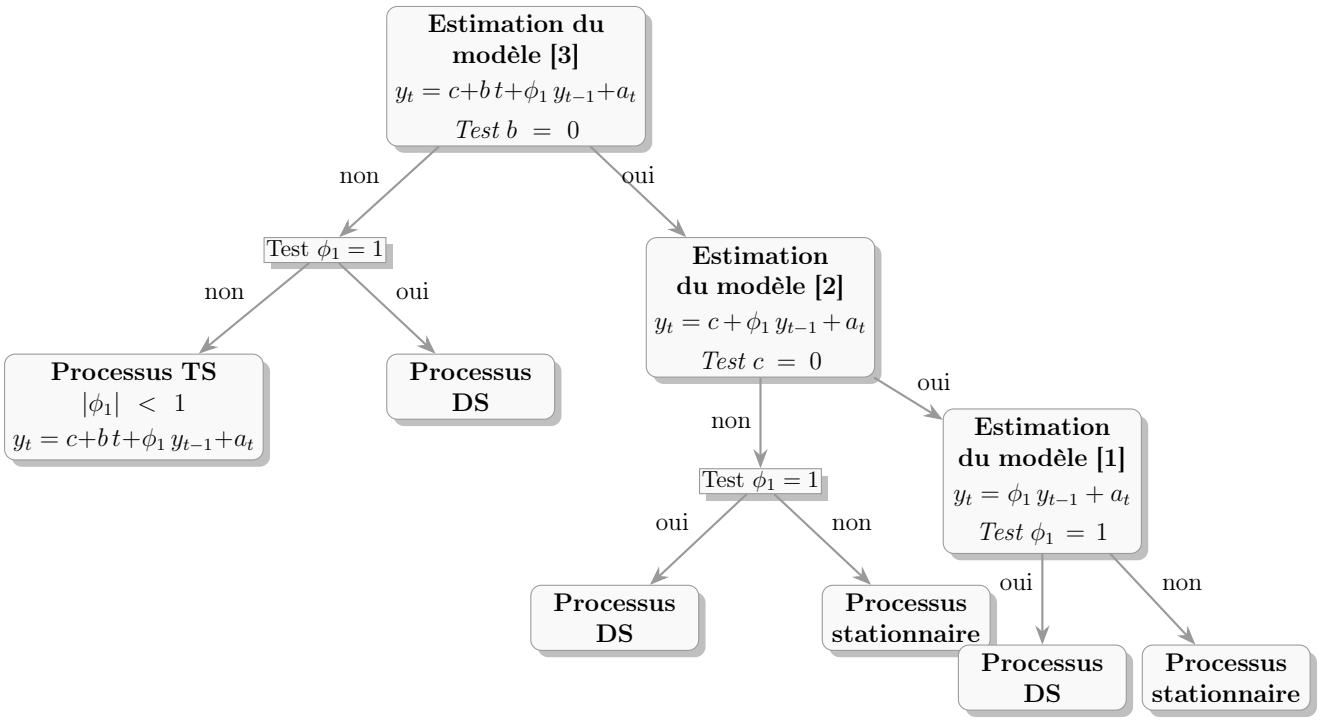


FIGURE 2.3 – Stratégie simplifiée des tests de racine unitaire

2.3 La Modélisation Univariée : Les Processus AR et MA

2.3.1 Les Processus Autorégressifs d'ordre p : $AR(p)$

Un processus autoregressif d'ordre p, noté $AR(p)$, stipule que la valeur actuelle de la série y_t dépend linéairement de ses p valeurs passées, augmentée d'un terme de perturbation.

Sa spécification mathématique s'écrit :

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \cdots + \phi_p y_{t-p} + \epsilon_t \tag{2.20}$$

Où c est une constante, ϕ_i sont les paramètres autorégressifs à estimer, et ϵ_t est un bruit blanc pur tel que $\epsilon_t \sim i.i.d.\, N(0, \sigma^2)$.

Condition de stationnarité : Pour qu'un processus $AR(p)$ soit stationnaire, il faut que toutes les racines du polynôme caractéristique $\Phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p = 0$ soient structuralement situées en dehors du cercle unité.

2.3.2 Les Processus Moyenne Mobile d'ordre q : $MA(q)$

Contrairement au modèle AR, un processus Moyenne Mobile d'ordre q, noté $MA(q)$, modélise la série y_t non pas en fonction de ses valeurs passées, mais en fonction des chocs (ou erreurs de prévision) contemporains et passés. Il s'exprime de la manière suivante :

$$y_t = \mu + \epsilon_t - \theta_1 \epsilon_{t-1} - \theta_2 \epsilon_{t-2} - \cdots - \theta_q \epsilon_{t-q} \tag{2.21}$$

Où μ représente la moyenne à long terme de la série, θ_j sont les coefficients associés aux chocs passés, et ϵ_t est un bruit blanc. Par définition, tout processus $MA(q)$ structuré sur un bruit blanc est stationnaire en variance et en covariance, quelle que soit la valeur des coefficients θ_j.

2.3.3 L'extension aux processus mixtes : $ARMA(p, q)$

Lorsque la dynamique d'une série temporelle présente à la fois une mémoire sur ses niveaux passés et une sensibilité aux chocs récents, la théorie combine les deux structures précédentes au sein d'un modèle mixte appelé $ARMA(p, q)$:

$$y_t = c + \sum_{i=1}^{p} \phi_i y_{t-i} + \epsilon_t - \sum_{j=1}^{q} \theta_j \epsilon_{t-j} \tag{2.22}$$

Cette modélisation offre un cadre parcimonieux, permettant souvent de capter des dynamiques complexes avec un nombre restreint de paramètres (p et q) par rapport à un modèle AR ou MA pur de rang très élevé.

2.4 Les Tests de Racine Unitaire

Afin de déterminer de manière rigoureuse la nature de la non-stationnarité d'une série chronologique (déterministe ou stochastique) et de valider le choix de la méthode de

stationnarisation, il est indispensable d'appliquer des tests de racine unitaire. Trois tests principaux s'imposent comme les standards de la littérature économétrique.

2.4.1 Le test d'ADF

Le test développé par Dickey et Fuller (1979, 1981) vise à détecter la présence d'une racine unitaire (processus DS). La version augmentée permet de corriger le problème d'autocorrélation des résidus en introduisant des retards de la variable différenciée.

Le test repose sur l'estimation par les MCO de l'équation générale suivante :

$$\Delta y_t = \alpha + \beta t + \rho y_{t-1} + \sum_{i=1}^{k} \delta_i \Delta y_{t-i} + \epsilon_t \tag{2.23}$$

Où t est la tendance temporelle, Δy_{t-i} représente les termes de retards introduits pour blanchir le résidu, et k est le nombre de retards optimaux.

La stratégie de test suit une procédure séquentielle descendante (du modèle le plus complet vers le modèle le plus simple) pour tester les hypothèses :

- $H_0 : \rho = 0$ (Présence d'une racine unitaire, la série est non stationnaire de type DS).
- $H_1 : \rho < 0$ (Absence de racine unitaire, la série est stationnaire ou de type TS).

2.4.2 Le test de PP

Le test PP (1988) propose une alternative au test ADF pour gérer l'autocorrélation et l'hétéroscédasticité potentielle des perturbations. Au lieu d'augmenter l'équation de régression avec des retards de Δy_t pour blanchir les résidus, Phillips et Perron conservent l'équation de Dickey-Fuller standard mais appliquent une correction non paramétrique directement aux statistiques de test.
Les hypothèses restent identiques à celles du test ADF :

- H_0 : Présence d'une racine unitaire (processus DS).
- H_1 : Absence de racine unitaire (processus stationnaire ou TS).

Ce test se révèle souvent plus puissant que le test ADF lorsque les résidus du processus initial présentent des formes complexes d'hétéroscédasticité.

2.5 La Théorie de la Cointégration

L'existence de tendances stochastiques non stationnaires (processus DS) au sein des variables macroéconomiques et financières soulève des défis analytiques majeurs. Si l'on estime une relation linéaire en niveau entre deux ou plusieurs variables non stationnaires et indépendantes, les outils d'estimation classiques échouent en raison du phénomène de régression fallacieuse. Ce biais statistique se traduit par un coefficient de détermination R^2 anormalement élevé et des tests de significativité fortement déformés, laissant croire à une relation économique là où il n'y a qu'une dérive temporelle commune.

Pour surmonter cette barrière théorique sans devoir systématiquement renoncer à l'information contenue dans les niveaux d'origine des séries (ce que ferait une différenciation systématique), Engle et Granger (1987), puis Johansen (1988), ont formalisé le concept de cointégration. Ce cadre permet d'étudier l'existence de relations d'équilibre stables de long terme entre des processus non stationnaires.

2.5.1 Définition mathématique de la cointégration

Soit un ensemble de K variables temporelles regroupées dans un vecteur $Y_t = (y_{1,t}, y_{2,t}, \ldots, y_{K,t})'$. On suppose que toutes les composantes de ce vecteur sont intégrées du même ordre, typiquement d'ordre 1, ce que l'on note $y_{i,t} \sim I(1)$.

Les composantes du vecteur Y_t sont dites cointégrées d'ordre $(1,1)$, noté $Y_t \sim CI(1,1)$, s'il existe un vecteur multiplicateur β (non nul) tel que la combinaison linéaire résultante z_t soit intégrée d'un ordre inférieur, à savoir stationnaire $I(0)$:

$$z_t = \beta' Y_t \sim I(0) \tag{2.24}$$

Le vecteur β est structurellement qualifié de **vecteur de cointégration**. Sur le plan conceptuel, la relation $\beta' Y_t = 0$ définit l'état d'équilibre de long terme. Bien que chaque variable prise individuellement puisse dévier de sa trajectoire de manière erratique et non stable à court terme, le terme z_t — représentant l'erreur d'équilibre ou l'écart à la cible — reste confiné dans des limites stables et stationnaires, témoignant d'une force de rappel systémique.

2.5.2 Le Test de Cointégration de Johansen

Pour identifier de manière exhaustive le nombre de relations de cointégration indépendantes (le rang de cointégration, noté r) au sein d'un système multivarié, la méthodologie

du maximum de vraisemblance développée par Søren Johansen (1988, 1991) constitue le standard théorique. Contrairement à l'approche bilatérale d'Engle-Granger, Johansen appréhende la cointégration à travers l'analyse matricielle d'un système vectoriel complet.

La détermination du rang r s'appuie sur l'évaluation de deux tests d'hypothèses complémentaires basés sur les valeurs propres (λ_i) triées par ordre décroissant :

1. Le test de la trace (Trace Test) :

Ce test examine l'hypothèse nulle selon laquelle il existe au plus r vecteurs de cointégration, contre l'hypothèse alternative d'un nombre de vecteurs strictement supérieur à r. Sa formulation mathématique s'écrit :

$$\lambda_{\text{trace}}(r) = -T \sum_{i=r+1}^{K} \ln(1 - \hat{\lambda}_i) \tag{2.25}$$

Où T représente le volume de l'échantillon et $\hat{\lambda}_i$ les valeurs propres estimées de la matrice d'impact.

2. Le test de la valeur propre maximale (Max-Eigenvalue Test) :

Ce test évalue l'hypothèse nulle selon laquelle le système comporte exactement r relations de cointégration, contre l'hypothèse alternative de la présence de $r+1$ relations distinctes. Sa statistique est définie par :

$$\lambda_{\max}(r, r+1) = -T \ln(1 - \hat{\lambda}_{r+1}) \tag{2.26}$$

Ces deux statistiques sont ensuite confrontées aux valeurs critiques issues des tables de Johansen pour déterminer de façon rigoureuse la dimension de l'espace de cointégration du système étudié.

2.6 Fondements théoriques du VECM

Dans l'analyse des séries temporelles économiques et financières, il est fréquent de rencontrer des variables non stationnaires qui évoluent ensemble sur le long terme. Les modèles classiques comme le VAR permettent de capturer les dynamiques de court terme, mais ils ne prennent pas en compte les relations structurelles de long terme entre les variables. C'est pour répondre à cette limite qu'a été développé le modèle VECM (Vector Error Correction Model), qui intègre à la fois les ajustements de court terme et les équilibres de

long terme grâce au concept de cointégration.

2.6.1 Définition

Le VECM est une extension du modèle VAR adaptée aux séries temporelles non stationnaires mais cointégrées.

— Il combine la dynamique de court terme (différences des variables) avec les relations d'équilibre de long terme (vecteurs de cointégration).
— Il est particulièrement utilisé en macroéconomie et en finance pour modéliser des variables qui évoluent ensemble sur le long terme (ex. taux de change et prix, PIB et consommation).

2.6.2 Formule générale

Un modèle VAR(p) s'écrit :

$$Y_t = A_1 Y_{t-1} + \cdots + A_p Y_{t-p} + \varepsilon_t$$

On obtient alors le VECM :

$$\Delta Y_t = \Pi Y_{t-1} + \sum_{i=1}^{p-1} \Gamma_i \Delta Y_{t-i} + \varepsilon_t$$

Où :

— ΔY_t : variations des variables (court terme),
— $\Pi = \alpha\beta'$: matrice de cointégration,
— β : vecteurs de cointégration (relations de long terme),
— α : coefficients d'ajustement (vitesses de correction),
— Γ_i : matrices capturant les effets dynamiques de court terme.

2.6.3 Hypothèses du modèle VECM

— **Intégration I(1)** : les séries sont non stationnaires en niveau mais stationnaires en première différence.

— **Existence de cointégration** : il existe au moins une combinaison linéaire stationnaire des variables.

— **Erreurs blanches** : les résidus ε_t sont non autocorrélés, de moyenne nulle et variance constante.

— **Nombre de retards approprié** : le modèle doit inclure suffisamment de retards pour capturer la dynamique sans sur-paramétrisation.

2.6.4 Utilité du modèle VECM

— Modéliser les relations de long terme : identifier des équilibres économiques stables (ex. parité de pouvoir d'achat).

— Analyser les ajustements de court terme : comprendre comment les variables réagissent aux déséquilibres.

— Prévisions : produire des projections cohérentes avec les relations structurelles.

— Politiques économiques : évaluer l'impact des chocs et la vitesse de retour à l'équilibre.

2.7 Les tests de diagnostic

Après l'estimation d'un modèle VECM, il est indispensable de vérifier sa validité statistique et économétrique. En effet, un modèle correctement spécifié doit non seulement respecter les hypothèses théoriques de stationnarité et de cointégration, mais aussi présenter des résidus conformes aux propriétés attendues (absence d'autocorrélation, normalité, homoscédasticité). Les tests de diagnostic permettent d'évaluer la qualité de l'ajustement, de détecter d'éventuelles anomalies et de s'assurer que les résultats obtenus sont fiables pour l'interprétation économique et la prévision.

Ces tests constituent donc une étape essentielle pour confirmer la robustesse du modèle et garantir que les relations de court et de long terme mises en évidence par le VECM ne sont pas biaisées par des problèmes statistiques.

2.7.1 Test d'autocorrélation des résidus

Le test d'autocorrélation des résidus repose sur l'idée que, dans un modèle correctement spécifié, les erreurs ε_t doivent se comporter comme un bruit blanc : indépendantes dans le temps, de moyenne nulle et de variance constante. Si les résidus présentent une dépendance temporelle, cela signifie que le modèle n'a pas capturé toute la dynamique des données, ce qui remet en cause la validité des estimations.

Le principe théorique s'appuie sur la corrélation entre les résidus et leurs propres retards. On considère la régression auxiliaire suivante :

$$\varepsilon_t = \rho_1 \varepsilon_{t-1} + \rho_2 \varepsilon_{t-2} + \cdots + \rho_q \varepsilon_{t-q} + u_t$$

Où u_t est un bruit blanc. Si tous les coefficients ρ_i sont nuls, alors les résidus ne présentent pas d'autocorrélation.

Les hypothèses testées sont donc :

— $H_0 : \rho_1 = \rho_2 = \cdots = \rho_q = 0 \quad \rightarrow \quad$ les résidus sont indépendants (pas d'autocorrélation)
— $H_1 : \exists\ \rho_i \neq 0 \quad \rightarrow \quad$ les résidus présentent une autocorrélation

Le test peut être mené à l'aide de statistiques comme le test de Ljung-Box ou le test LM de Breusch-Godfrey, qui permettent de détecter si les corrélations résiduelles sont significatives.

Ainsi, le test d'autocorrélation des résidus permet de vérifier si le modèle VECM a correctement capturé la dynamique des séries. En cas de rejet de H_0, il est nécessaire de revoir la spécification du modèle (ajout de retards, modification du rang de cointégration ou réexamen des hypothèses structurelles).

2.7.2 Test de normalité (Jarque-Bera)

Le test de normalité des résidus vise à vérifier si les perturbations ε_t suivent une loi normale multivariée. Cette propriété est requise pour garantir la validité de l'inférence statistique (tests de Student et de Fisher) et pour fiabiliser les intervalles de confiance lors des prévisions.
Le principe théorique s'appuie sur la confrontation de la distribution des résidus avec une distribution théorique normale. Le test de Jarque-Bera multivarié, combiné à l'approche de Doornik et Hansen (1994), repose sur l'estimation de la statistique globale suivante :

$$DH = Z_s' Z_s + Z_k' Z_k \sim \chi^2(2k)$$

Où Z_s est le vecteur des coefficients d'asymétrie (skewness) transformés, Z_k est le vecteur des coefficients d'aplatissement (kurtosis) transformés, et k représente le nombre de variables endogènes du système. Si les résidus sont normaux, la statistique DH tend vers zéro.

Les hypothèses testées sont les suivantes :

— H_0 : Distribution Normale $\rightarrow$ les résidus suivent une loi normale multivariée.

— H_1 : Distribution Non Normale → les résidus présentent un écart significatif à la normalité.

Ainsi, le test de normalité permet de valider le comportement statistique des erreurs. En cas de rejet de H_0 sur des données réelles, le recours au Théorème Central Limite reste légitime si la taille de l'échantillon est supérieure à 30 observations ($N > 30$), ce qui préserve les propriétés asymptotiques des estimateurs et la validité du modèle VECM.

2.7.3 Test d'hétéroscédasticité des résidus

Le test d'hétéroscédasticité des résidus vise à vérifier que la variance des perturbations ε_t est constante dans le temps (homoscédasticité). Si la variance des erreurs change au cours de la période d'étude, cela signifie que les estimateurs des moindres carrés ne sont plus efficaces, ce qui fausse le calcul des écarts-types et invalide les tests de significativité statistique. Le principe théorique s'appuie sur la recherche de relations entre la variance des résidus et les variables explicatives du modèle. Le test consiste à régresser les carrés des résidus sur les variables du système introduites en niveau et au carré. Pour les échantillons de taille modérée, la spécification sans termes croisés (No Cross Terms) est privilégiée, excluant les interactions (produits croisés) entre les variables afin de préserver les degrés de liberté.

Les hypothèses testées sont les suivantes :

— H_0 : Homoscédasticité → la variance des résidus est constante dans le temps.
— H_1 : Hétéroscédasticité → la variance des résidus n'est pas constante.

Le test est mené à l'aide du test de White multivarié, dont la statistique globale suit asymptotiquement une loi du χ^2 (Chi-deux).

Ainsi, le test de White permet de s'assurer de la stabilité temporelle de la variance des erreurs. En cas de rejet de H_0, il convient d'introduire des variables muettes (*dummies*) pour corriger l'impact de chocs structurels ou de revoir la forme fonctionnelle du modèle.

2.7.4 Test de stabilité du modèle

Un modèle est considéré stable lorsque les racines caractéristiques associées au polynôme des retards se trouvent strictement à l'extérieur du cercle unité. Cela signifie que les chocs affectant les variables s'atténuent progressivement au lieu de s'amplifier indéfiniment.

Les hypothèses testées sont donc :

— H_0 : le modèle est stable (toutes les racines sont à l'extérieur du cercle unité).

— H_1 : le modèle est instable (au moins une racine est à l'intérieur ou sur le cercle unité).

Méthodes utilisées

— **Test des racines caractéristiques :** vérifie la position des racines du polynôme associé au VECM.
— **Test de stabilité des paramètres :** examine si les coefficients α, β et Γ_i restent constants sur différentes sous-périodes.
— **Tests de rupture structurelle (CUSUM, CUSUMSQ) :** détectent des changements significatifs dans la dynamique du modèle.

2.8 Approches ML pour séries temporelles

Le modèle VECM constitue un outil de référence pour analyser la dynamique des séries et générer des prévisions macroéconomiques cohérentes avec la théorie économique de long terme. Cependant, ces prévisions reposent sur des équations strictement linéaires et un cadre paramétrique contraignant, ce qui peut limiter leur précision face à des chocs économiques abrupts ou des comportements asymétriques des agents.

Afin d'enrichir l'analyse et de fiabiliser l'aide à la décision au sein HCP, cette section introduit l'approche par Machine Learning comme outil complémentaire de prévision. L'objectif est de confronter la méthode de prédiction classique du VECM à des algorithmes de régression supervisée non paramétriques. En exploitant la capacité de ces derniers à capter des structures de données complexes et non linéaires, cette démarche comparative permet de tester si l'intégration du Machine Learning offre un gain de précision significatif dans la trajectoire prévisionnelle (FBC).

2.8.1 Principaux modèles ML pour séries temporelles

— **LSTM/GRU**

— Réseaux récurrents adaptés aux dépendances séquentielles.
— Bonne performance pour des horizons courts/moyens.
— Limite : difficulté à gérer des horizons très longs.

— **Transformers spécialisés**

— Exemples : TimesFM (Google), Chronos-2 (Amazon), Moirai-2 (Salesforce).
— Pré-entraînés sur des milliards de points temporels.
— Excellents pour horizons longs et multi-variables.

— Avantage : peu de réglages nécessaires, forte généralisation.

— **Random Forest / XGBoost**

— Modèles d'ensemble robustes.
— Utilisés avec features dérivées (retards, tendances, saisonnalité).
— Plus simples à mettre en œuvre mais moins performants que les deep learning modernes.

— **CNN 1D**

— Capturent des motifs locaux dans les séries.
— Souvent combinés avec LSTM pour améliorer la précision.

2.8.2 Choix du modèle optimal

Compte tenu de la taille réduite de notre échantillon, l'utilisation de modèles complexes tels que les réseaux neuronaux profonds (LSTM, GRU, CNN 1D) n'est pas optimale, car ces architectures nécessitent un volume de données conséquent pour exprimer pleinement leur potentiel prédictif. Dans un contexte de données limitées, il est préférable de privilégier un modèle robuste, interprétable et capable de fournir des résultats stables malgré la contrainte de taille d'échantillon.

Ainsi, le choix s'oriente vers XGBoost, une implémentation optimisée du Gradient Boosting. Ce modèle est particulièrement adapté aux petits jeux de données, car il exploite efficacement les variables explicatives dérivées (retards, tendances, saisonnalité) et intègre des mécanismes de régularisation qui limitent le sur-apprentissage. De plus, sa simplicité de mise en œuvre et son interprétabilité en font un candidat idéal pour une comparaison directe avec le modèle VECM.

En conséquence, XGBoost est retenu comme modèle optimal pour notre étude, en raison de sa robustesse face aux contraintes de données limitées et de sa pertinence dans un cadre empirique appliqué aux séries temporelles économiques.

2.8.3 XGBoost

XGBoost est un algorithme d'apprentissage supervisé puissant basé sur des arbres de décision. Son principe consiste à combiner plusieurs modèles simples (des arbres courts) de manière séquentielle : chaque nouvel arbre est construit spécifiquement pour corriger les erreurs de prédiction commises par les arbres précédents. Il intègre également des pénalités mathématiques (régularisation) pour éviter le sur-apprentissage, ce qui le rend

particulièrement performant et rapide sur les données tabulaires et les séries temporelles.

1- Hypothèses Méthodologiques du Modèle

Contrairement aux modèles économétriques qui exigent la validation d'hypothèses statistiques strictes (normalité, homoscédasticité, stationnarité et cointégration), les modèles de Machine Learning s'affranchissent de ces contraintes de distribution. Ils reposent néanmoins sur les hypothèses opérationnelles suivantes :

- **Hypothèse Markovienne (Complétude de l'information)** : En fixant un niveau de retard égal à 1 (*Lag = 1*), on suppose que toute l'information historique pertinente à l'instant $t-1$ suffit à expliquer la dynamique de l'investissement à l'instant t.
- **Hypothèse de Stabilité Structurelle** :Le modèle suppose que les relations non linéaires apprises sur la période d'entraînement (2015-2023) restent homogènes et valides sur la période de test et de projection (2024-2026).
- **Hypothèse Additive des Fonctions de Score** : La prédiction finale est modélisée comme la somme pondérée des réponses de chaque arbre individuel :

$$\hat{y}_t = \sum_{k=1}^{K} f_k(X_{t-1})$$

Où K représente le nombre total d'arbres construits par l'algorithme et f_k la contribution du k^{me} arbre de décision.

- **Hypothèse *Ceteris Paribus* en Projection** : Pour la prévision future de l'année 2026, l'absence de scénarios exogènes implique que les variables d'environnement (PIB, Inflation, Taux, Crédit) sont maintenues constantes à leur dernier niveau connu.

2- Algorithme du modèle XGBoost

Entrées :

- Jeu de données : (X, Y)
- Nombre d'arbres : M
- Taux d'apprentissage : η
- Paramètres de régularisation : λ, γ

Étape 1 : Initialisation

On commence par une prédiction initiale :

$$F_0(x) = \text{moyenne}(Y)$$

Étape 2 : Pour $m = 1$ **jusqu'à** M

1. Calculer les pseudo-résidus (erreurs de prédiction) :

$$r_i = y_i - F_{m-1}(x_i)$$

2. Entraîner un arbre $h_m(x)$ sur les pseudo-résidus.
3. Mettre à jour le modèle avec régularisation :

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

Étape 3 : Retourner le modèle final

$$F(x) = F_0(x) + \eta \sum_{m=1}^{M} h_m(x)$$

Sortie :

Valeur prédite ou estimation finale.

2.8.4 Random Forest

Le Random Forest est un algorithme d'ensemble basé sur des arbres de décision, qui combine le principe du bagging et la sélection aléatoire de variables pour produire des modèles robustes en classification et régression. Il repose sur le vote majoritaire (classification) ou la moyenne (régression) des prédictions issues de plusieurs arbres indépendants.

Algorithme de Random Forest

— **Échantillonnage bootstrap**

Chaque arbre est construit sur un échantillon aléatoire des données d'entraînement, tiré avec remise. En moyenne, 63,2 % des observations apparaissent dans chaque échantillon, les autres étant dites OOB.

— **Construction des arbres**

À chaque nœud, un sous-ensemble aléatoire de variables est sélectionné (par exemple $m = \sqrt{p}$ pour la classification). La meilleure règle de division est choisie parmi ces variables selon un critère comme l'indice de Gini ou l'entropie.

— **Agrégation des prédictions**

En classification : chaque arbre vote pour une classe, et la classe majoritaire est retenue. En régression : la prédiction finale est la moyenne des prédictions des arbres.

— **Évaluation OOB**

Les observations non utilisées pour un arbre servent à estimer l'erreur de généralisation, sans besoin de validation croisée.

L'analyse des principaux modèles de Machine Learning appliqués aux séries temporelles montre que les réseaux neuronaux profonds exigent un volume de données plus important que celui disponible dans notre étude. En revanche, les modèles d'ensemble comme Random Forest et surtout XGBoost se révèlent plus adaptés aux petits échantillons. Ainsi, XGBoost est retenu comme modèle optimal, tandis que Random Forest servira de référence comparative pour positionner la précision de l'ensemble.

2.9 Conclusion

Ce chapitre a présenté les bases théoriques indispensables à l'analyse des séries temporelles, en mettant en évidence les notions de stationnarité, de cointégration et les principaux modèles économétriques, ainsi que les approches modernes de Machine Learning. Cette complémentarité théorique constitue le cadre de référence de la partie empirique, qui vise à comparer ces méthodes afin d'identifier celle offrant les prévisions les plus pertinentes pour l'économie marocaine.

Chapitre 3

Etude pratique

Après avoir présenté les aspects théoriques et méthodologiques de notre travail, nous passons à l'étude pratique. Ce chapitre est consacrée à l'application des méthodes retenues sur des données réelles afin d'évaluer leur pertinence et leur efficacité. Nous y décrivons les données utilisées, les étapes de prétraitement, la mise en œuvre des modèles ainsi que l'analyse et l'interprétation des résultats obtenus.

3.1 Données et Méthodologie d'Analyse

Cette section est consacrée à la présentation, la sélection et l'analyse descriptive des données qui serviront de base à notre modélisation.

3.1.1 Sources et Collecte des Données

Conformément à notre plan de travail, nous détaillons ici les sources institutionnelles et la nature des variables retenues.

Données du Haut-Commissariat au Plan

En tant qu'organe principal du système statistique national, le HCP produit les indicateurs macroéconomiques et les comptes de la nation selon les normes internationales. Dans le cadre de notre étude, cette source a été sollicitée pour l'extraction des agrégats réels de l'économie marocaine :

— **La Formation Brute de Capital (FBC) :** est un agrégat de la comptabilité nationale qui mesure la valeur des investissements réalisés dans une économie au cours d'une période donnée. Elle correspond à l'acquisition d'actifs fixes (biens durables utilisés dans la production) ainsi qu'aux variations de stocks de plus l'acquisitions nettes d'objets de valeur.

— **Le Produit Intérieur Brut (PIB) :** Introduit comme variable macroéconomique d'accompagnement fondamentale, le PIB permet de capter l'effet d'accélérateur de l'investissement (l'impact de la croissance économique générale sur la décision d'investir des agents économiques).
— **L'Inflation :** est la hausse générale et durable du niveau des prix des biens et services dans une économie. Elle est mesurée à partir de l'IPC qui est extrait directement des données du HCP, en calculant la variation en pourcentage de cet indice entre deux périodes. Cette mesure permet de refléter l'évolution du coût de la vie et d'ajuster les variables économiques en termes réels

Données de Bank Al-Maghrib

La banque centrale du Maroc, Bank Al-Maghrib, est la source de référence pour l'ensemble des indicateurs monétaires et financiers du pays. Son apport est indispensable pour quantifier le coût de l'argent et les conditions de financement sur le marché national :

— **Le Taux Débiteur :** Cette variable, issue des publications de Bank Al-Maghrib, mesure le coût effectif du crédit au Maroc. Elle est exploitée dans notre modèle comme la variable explicative principale afin de capter l'impact direct du coût de l'argent sur l'investissement, permettant ainsi de vérifier si une hausse des taux freine les projets des entreprises marocaines.

— **Le Crédit Bancaire :** Cette variable statistique, extraite également des bases de données de Bank Al-Maghrib, représente le volume global des financements accordés au secteur privé. Elle est exploitée comme variable de contrôle essentielle pour isoler l'effet du taux d'intérêt, car la décision d'investir ne dépend pas seulement du coût du crédit, mais aussi de la disponibilité de la liquidité et de l'accès effectif aux financements bancaires.

Période d'étude

Cette composante méthodologique délimite l'horizon temporel de notre analyse, qui s'étend de 2014 à 2025. L'utilisation de données à fréquence trimestrielle permet d'obtenir un échantillon total de 48 observations, offrant ainsi la profondeur statistique nécessaire pour capter finement les dynamiques de court terme, les effets de saisonnalité et les délais de transmission de la politique monétaire sur l'investissement au Maroc.

3.1.2 Spécification et Nature des Variables

— **La Variable Dépendante (FBC) :** Variable endogène à expliquer, utilisée pour mesurer la réaction de l'investissement marocain face à la conjoncture monétaire.

— **La Variable Explicative Principale (Taux Débiteur) :** Variable exogène majeure, introduite pour tester et quantifier l'impact direct du coût du crédit sur les décisions d'investissement.

— **La Variable de Contrôle 1 (Inflation) :** Variable de contrôle calculée à partir de l'IPC, indispensable pour convertir le taux d'intérêt nominal en taux réel.

— **La Variable de Contrôle 2 (Crédit Bancaire) :** Variable de contrôle permettant d'isoler l'effet du coût de l'argent en captant l'impact de la liquidité disponible.

3.1.3 Analyse des données

Description de la base de données

	trimestres	FBCF	PIB	IPC	inflation (%)	taux debiteur	credit bancaire
0	T1- 2014	77396.631162	245477.203600	100.0	NaN	5.96	598308
1	T2 -2014	77414.036872	250853.947152	100.2	NaN	5.98	617761
2	T3 -2014	79398.610374	251726.219018	100.5	NaN	6.03	621656
3	T4 -2014	73979.721592	253396.630230	100.8	NaN	6.03	620796
4	T1- 2015	75522.450321	264406.792894	101.0	1.0	5.81	615976

TABLE 3.1 – Data utilisée

Traitement des données

La première phase de notre étude a consisté en un traitement rigoureux des données historiques (nettoyage, gestion des valeurs manquantes) afin de fiabiliser les résultats de nos modèles.

Afin de garantir l'homogénéité des séries temporelles et de stabiliser les variances, les variables volumétriques (FBC, PIB et Crédit Bancaire) ont été transformées en logarithmes

(log). Cette opération permet de linéariser les relations et d'interpréter directement les futurs coefficients du modèle en termes d'élasticités.

	trimestres	IPC	inflation (%)	taux debiteur	log_fbcf	log_pib	log_credit
4	T1- 2015	101.0	1.000000	5.81	11.232185	12.485244	13.330963
5	T2 -2015	101.4	1.197605	5.93	11.348107	12.500753	13.342831
6	T3 -2015	101.7	1.194030	5.67	11.326042	12.510641	13.340620
7	T4 -2015	102.1	1.289683	5.49	11.315263	12.520755	13.343673
8	T1- 2016	102.4	1.386139	5.55	11.267184	12.501573	13.349014

TABLE 3.2 – Data nettoyée

Analyse exploratoire

	log_fbcf	taux debiteur	inflation (%)	log_pib	log_credit
count	44.000000	44.000000	44.000000	44.000000	44.000000
mean	11.496185	5.043636	2.720103	12.680280	13.503698
std	0.161307	0.467796	2.103349	0.150144	0.117746
min	11.220184	4.240000	1.000000	12.485244	13.330963
25%	11.415658	4.760000	1.467976	12.567138	13.390262
50%	11.469481	5.080000	1.793370	12.644804	13.509556
75%	11.548405	5.370000	2.848805	12.794450	13.621480
max	11.906946	5.930000	9.122203	13.003043	13.688923

TABLE 3.3 – EDA

Visualisation des données

Le graphique présente une analyse double axe de la relation entre l'investissement (FBC) et le coût du crédit (Taux débiteur) :

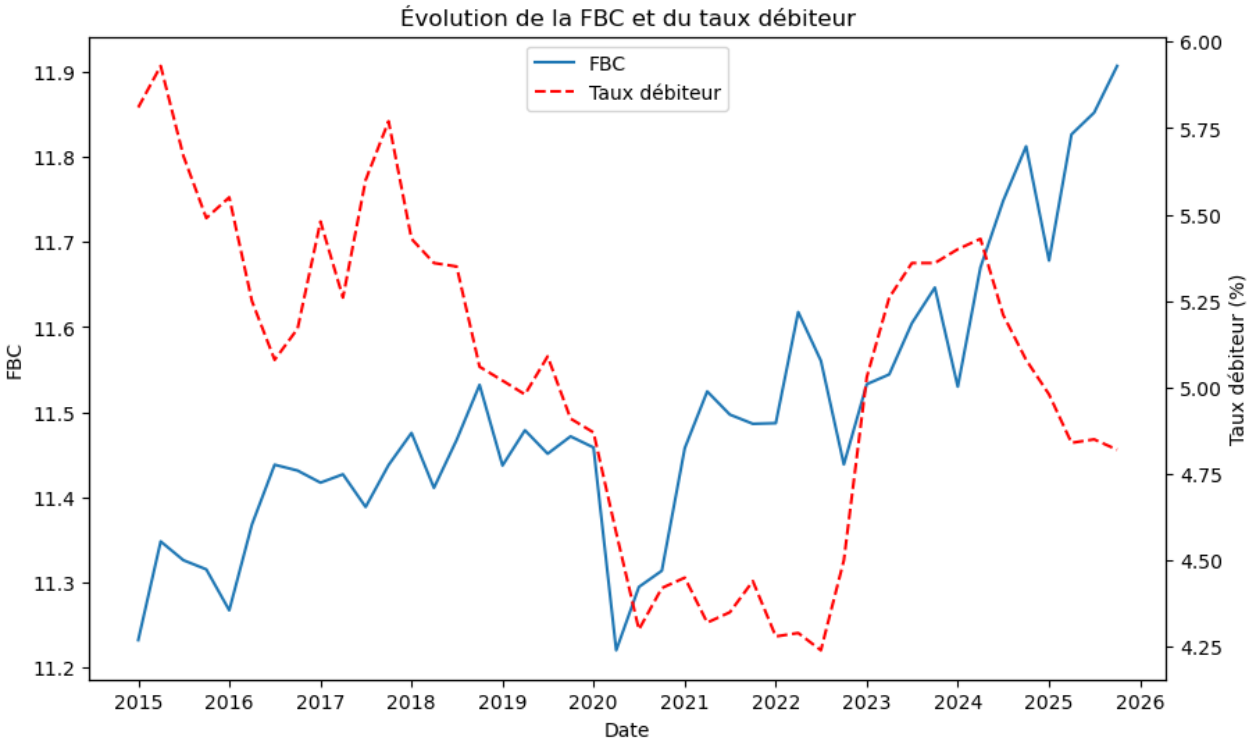


FIGURE 3.1 – FBC vs taux débiteur

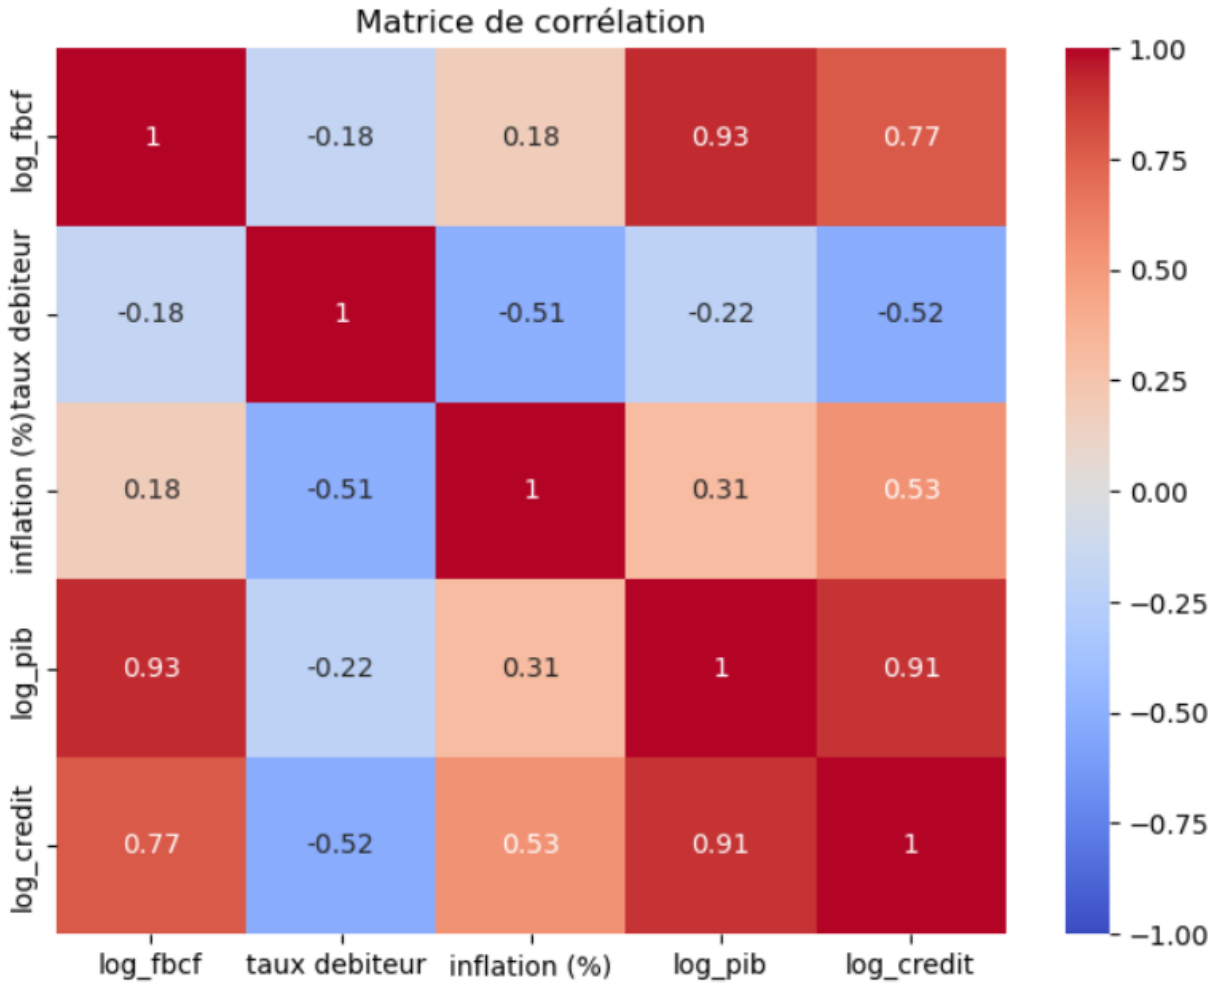
L'axe de gauche (FBC en bleu) : On observe une tendance globale à la hausse de la FBC sur la période, passant d'environ 11.2 en 2015 à plus de 11.9 vers 2026. On note une chute brutale et significative aux alentours de 2020, probablement liée au choc économique de la crise sanitaire, suivie d'une reprise volatile mais soutenue.

L'axe de droite (Taux débiteur en rouge pointillé) : Le taux débiteur exprime une tendance baissière sur le long terme, partant de sommets proches de 5.9% en 2015 pour atteindre des points bas autour de 4.25% vers 2022. On remarque une remontée temporaire entre 2023 et 2024 avant une nouvelle phase de déclin en fin de période.

3.1.4 Analyse statistique

Matrice de corrélation

Afin d'identifier les interdépendances premières entre les indicateurs retenus et de détecter d'éventuels problèmes de colinéarité, nous présentons ci-après la matrice de corrélation des variables.



1. Relation PIB et FBC : Une synergie quasi-totale

Coefficient : 0.93

Interprétation : C'est la corrélation la plus forte de la matrice. Elle est positive et proche de 1. Cela montre que l'investissement (FBCF) et la croissance économique (PIB) évoluent de manière quasi synchrone. En ingénierie financière, cela justifie l'utilisation d'un modèle de cointégration (VECM), car ces deux variables semblent partager une tendance commune de long terme.

2. Le rôle du Taux Débiteur : L'effet "frein"

Coefficients : -0.18 (avec FBC) et -0.22 (avec PIB)

Interprétation : La corrélation est négative, ce qui est conforme à la théorie économique : lorsque les taux d'intérêt augmentent, le coût de l'emprunt grimpe, ce qui tend à ralentir l'investissement et la consommation.

Nuance : La corrélation est relativement faible en valeur absolue (inférieure à 0.30), ce qui suggère que le taux débiteur n'est pas le seul déterminant de l'investissement ; d'autres facteurs (comme la confiance des entreprises ou les politiques publiques) jouent un rôle

majeur.

3. Inflation et Taux Débiteur : La relation monétaire
Coefficient : -0.51
Interprétation : C'est une corrélation négative modérée assez intéressante. On pourrait s'attendre à ce que les taux montent avec l'inflation (pour la freiner), mais ici la matrice montre une relation inverse sur ta période d'étude. Cela peut refléter une politique monétaire spécifique ou un décalage temporel dans les données.

4. Inflation et Croissance
Coefficients : 0.18 (avec FBC) et 0.31 (avec PIB)
Interprétation : La corrélation est positive mais faible. Une inflation modérée est souvent corrélée à une phase de croissance économique, ce qui semble être le cas ici.

3.2 Processus de modélisation économétrique

3.2.1 Les tests de spécification du modèle

Les Tests de Stationnarité

Pour orienter le choix du modèle économétrique, il est nécessaire d'étudier les propriétés de stationnarité des séries temporelles afin de détecter la présence éventuelle d'une racine unitaire. Nous testons les hypothèses suivantes :
H_0 : Présence d'une racine unitaire (la série est non-stationnaire).
H_1 : Absence de racine unitaire (la série est stationnaire).

Test ADF

— **la série log_fbc :**

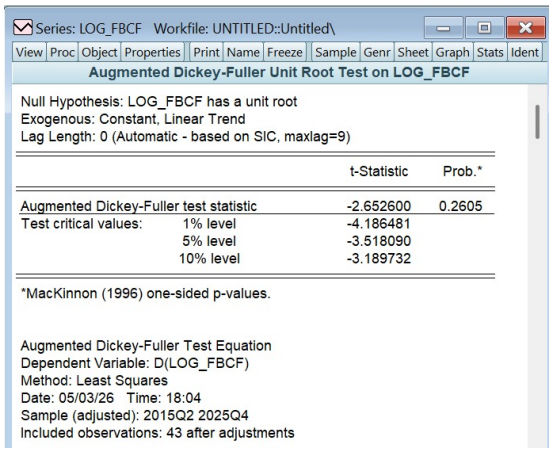


FIGURE 3.2 – log_fbc en niveau

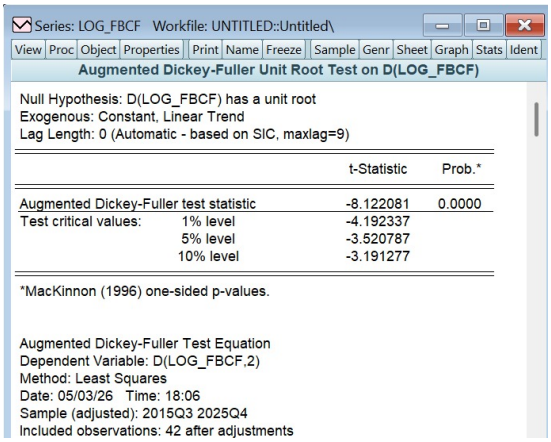


FIGURE 3.3 – log_fbc en 1ère différence

Les résultats montrent qu'en niveau, la p-value (0,2605) est supérieure à 5%, ce qui nous conduit à accepter H_0. En revanche, en différence première, la p-value tombe à 0,0000 ($< 0,05$), nous permettant de rejeter H_0 au profit de H_1. La variable est donc intégrée d'ordre 1, soit $I(1)$

— **la série taux debiteur :**

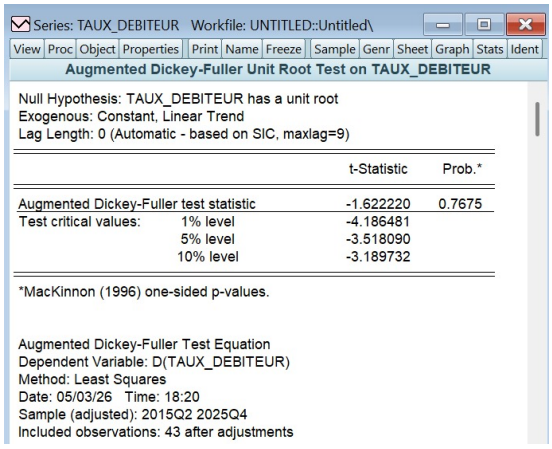


FIGURE 3.4 – taux debiteur en niveau

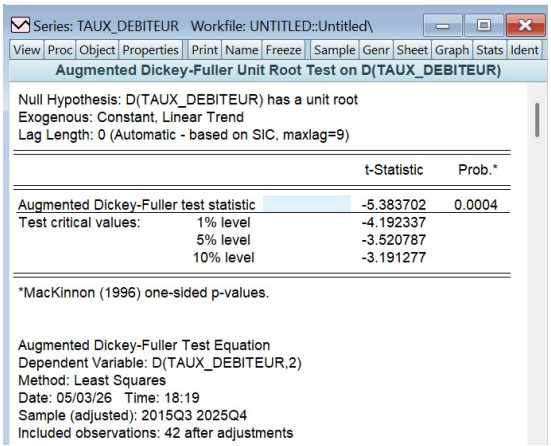


FIGURE 3.5 – taux debiteur en 1ère différence

Le taux débiteur suit exactement la même logique que log_fbc il n'est pas stable en niveau, mais sa différence l'est ,alors il est $I(1)$

— **la série log_pib :**

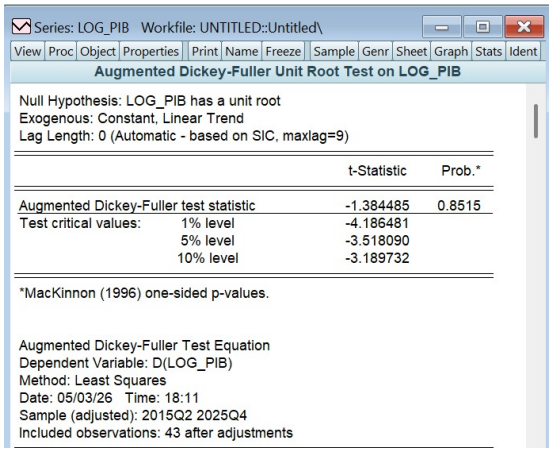


FIGURE 3.6 – log_pib en niveau

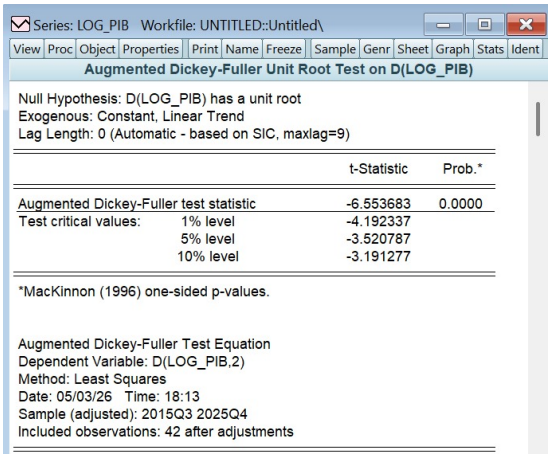


FIGURE 3.7 – log_pib en 1ère différence

La série log_pib présente une dynamique similaire à celle de log_fbc et du taux débiteur : elle n'est pas stationnaire en niveau, mais devient stationnaire en première différence. Elle est donc $I(1)$

— **la série log_crédit :**

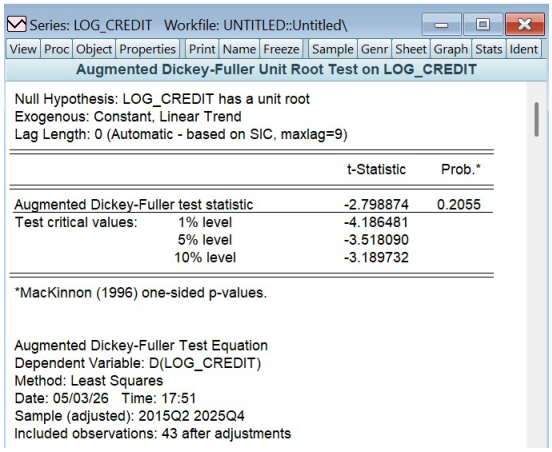


FIGURE 3.8 – log_crédit en niveau

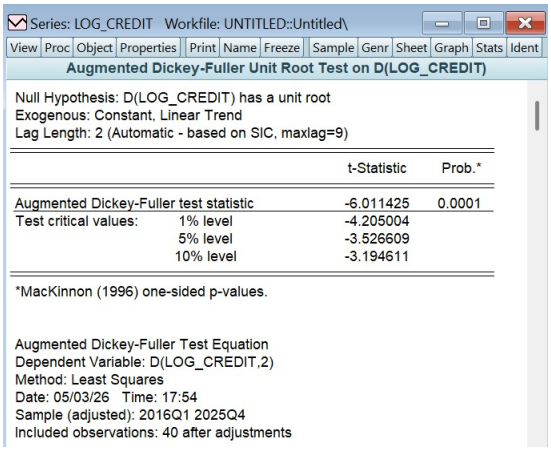


FIGURE 3.9 – log_crédit en 1ère différence

La dynamique de log_crédit est analogue à celle de log_fbc, du taux débiteur et de log_pib : non stationnaire en niveau, mais stationnaire en première différence, ce qui en fait une série $I(1)$

— **la série inflation :**

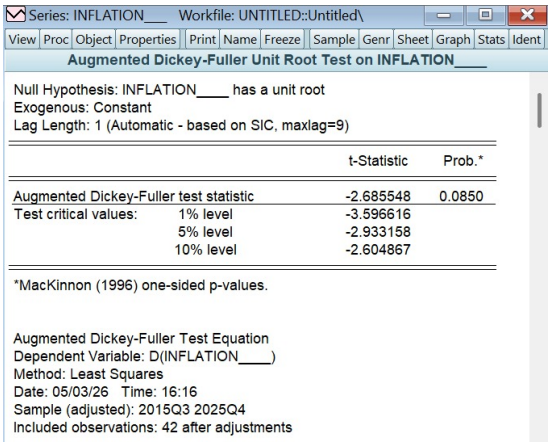


FIGURE 3.10 – inflation en niveau

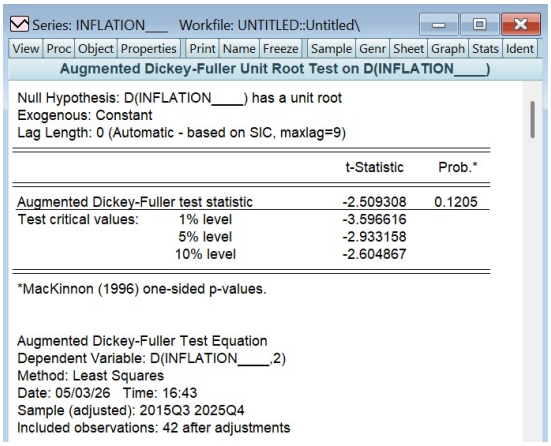


FIGURE 3.11 – inflation en 1ère différence

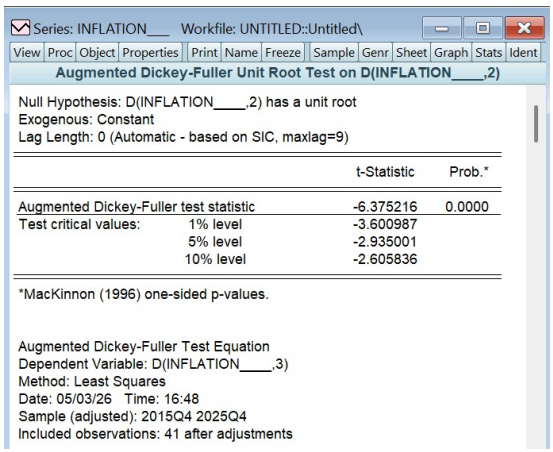


FIGURE 3.12 – inflation en 2nd différence

Contrairement aux autres variables, l'inflation n'est stationnaire ni en niveau, ni en différence première. Elle nécessite une seconde différenciation pour rejeter l'hypothèse nulle au seuil de 5 %, ce qui la définit comme une série intégrée d'ordre 2, soit $I(2)$.

Pour valider et consolider les résultats obtenus avec le test ADF, nous appliquons un second test de stationnarité :

Test PP

— **la série log_fbc :**

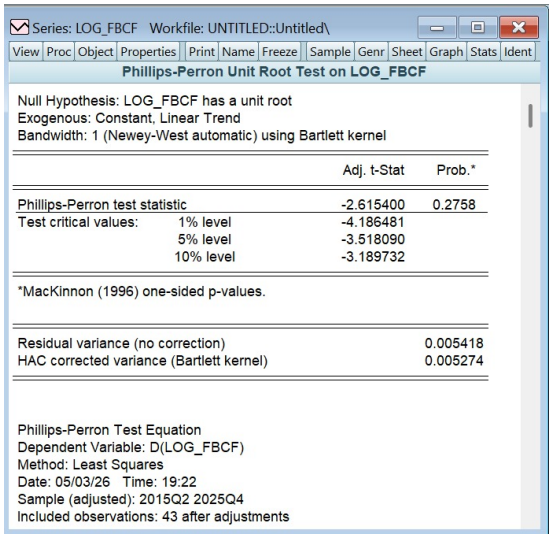


FIGURE 3.13 – log_fbc en niveau

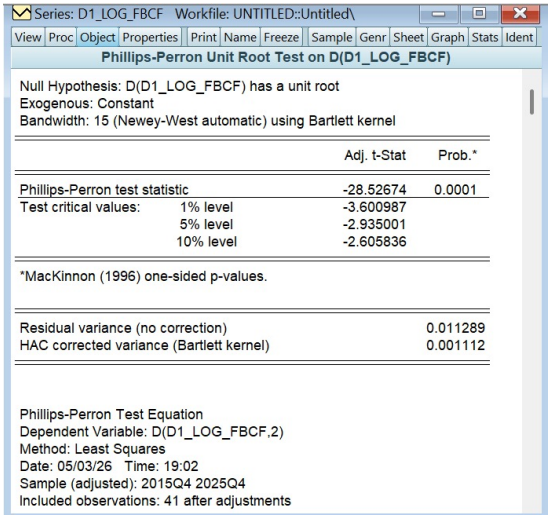


FIGURE 3.14 – log_fbc en 1ère différence

Les résultats du test de Phillips-Perron confirment qu'en niveau, la p-value (0,2758) est supérieure à 5 %, validant la non-stationnarité de la série. En différence première, la p-value passe à 0,0001 ($< 0,05$), ce qui permet de rejeter l'hypothèse nulle. La série est donc confirmée intégrée d'ordre 1, soit $I(1)$

— **la série taux debiteur :**

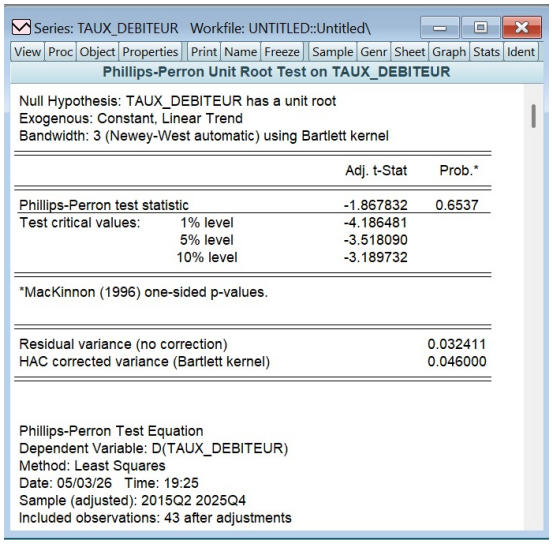


FIGURE 3.15 – taux debiteur en niveau

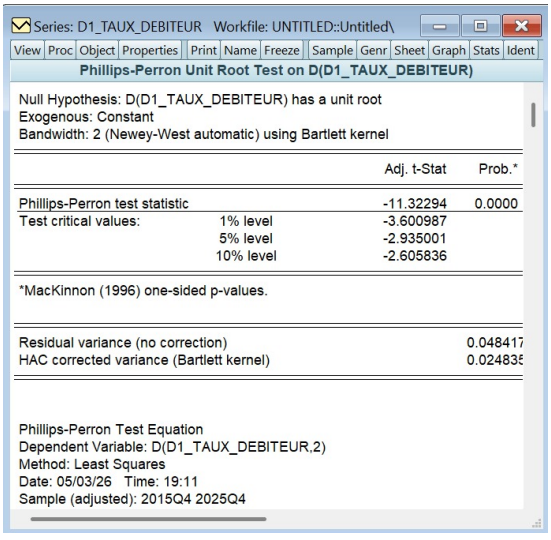
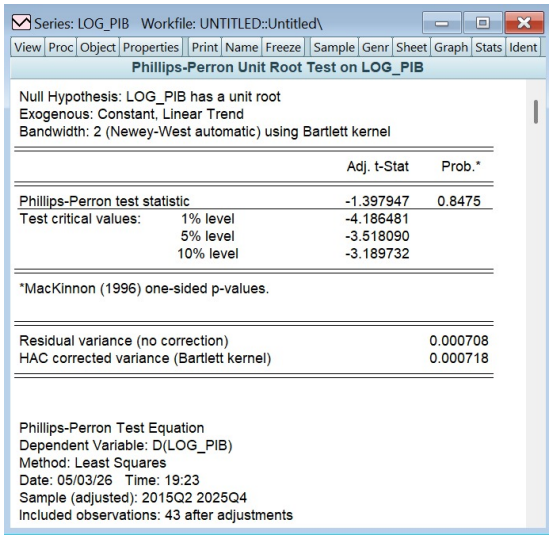


FIGURE 3.16 – taux debiteur en 1ère différence

Le taux debiteur partage le même comportement que le log_fbc la série présente une dérive en niveau, mais ses fluctuations deviennent stationnaires dès la première différenciation, ce qui valide son intégration d'ordre 1, soit $I(1)$.

— **la série log_pib :**


Series: LOG_PIB Workfile: UNTITLED::Untitled\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ident

Phillips-Perron Unit Root Test on LOG_PIB

Null Hypothesis: LOG_PIB has a unit root
Exogenous: Constant, Linear Trend
Bandwidth: 2 (Newey-West automatic) using Bartlett kernel

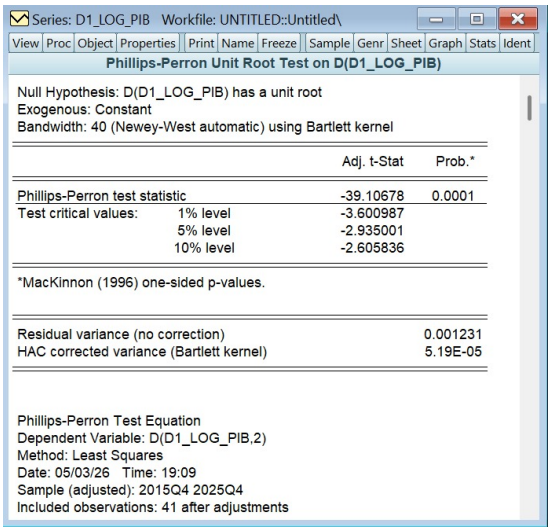
		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		-1.397947	0.8475
Test critical values:	1% level	-4.186481	
	5% level	-3.518090	
	10% level	-3.189732	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	0.000708
HAC corrected variance (Bartlett kernel)	0.000718

Phillips-Perron Test Equation
Dependent Variable: D(LOG_PIB)
Method: Least Squares
Date: 05/03/26 Time: 19:23
Sample (adjusted): 2015Q2 2025Q4
Included observations: 43 after adjustments

FIGURE 3.17 – log_pib en niveau


Series: D1_LOG_PIB Workfile: UNTITLED::Untitled\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ident

Phillips-Perron Unit Root Test on D(D1_LOG_PIB)

Null Hypothesis: D(D1_LOG_PIB) has a unit root
Exogenous: Constant
Bandwidth: 40 (Newey-West automatic) using Bartlett kernel

		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		-39.10678	0.0001
Test critical values:	1% level	-3.600987	
	5% level	-2.935001	
	10% level	-2.605836	

*MacKinnon (1996) one-sided p-values.

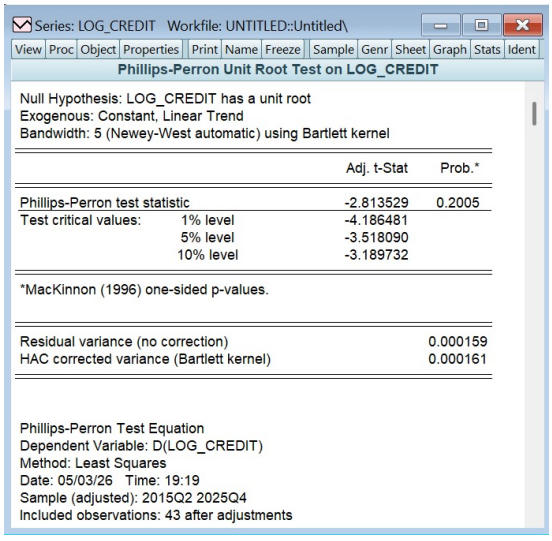
Residual variance (no correction)	0.001231
HAC corrected variance (Bartlett kernel)	5.19E-05

Phillips-Perron Test Equation
Dependent Variable: D(D1_LOG_PIB,2)
Method: Least Squares
Date: 05/03/26 Time: 19:09
Sample (adjusted): 2015Q4 2025Q4
Included observations: 41 after adjustments

FIGURE 3.18 – log_pib en 1ère différence

La série log_pib s'inscrit dans la même lignée que les variables précédentes : elle manifeste une instabilité en niveau, mais l'application d'une différence première permet d'annuler cette dérive, ce qui confirme sa nature de processus $I(1)$.

— **la série log_crédit :**


Series: LOG_CREDIT Workfile: UNTITLED::Untitled\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ident

Phillips-Perron Unit Root Test on LOG_CREDIT

Null Hypothesis: LOG_CREDIT has a unit root
Exogenous: Constant, Linear Trend
Bandwidth: 5 (Newey-West automatic) using Bartlett kernel

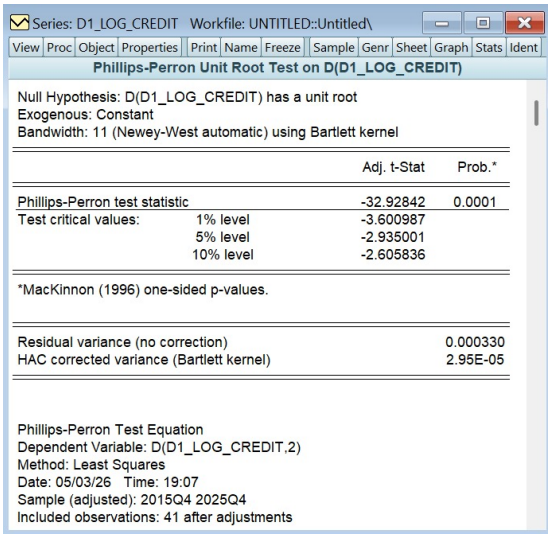
		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		-2.813529	0.2005
Test critical values:	1% level	-4.186481	
	5% level	-3.518090	
	10% level	-3.189732	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	0.000159
HAC corrected variance (Bartlett kernel)	0.000161

Phillips-Perron Test Equation
Dependent Variable: D(LOG_CREDIT)
Method: Least Squares
Date: 05/03/26 Time: 19:19
Sample (adjusted): 2015Q2 2025Q4
Included observations: 43 after adjustments

FIGURE 3.19 – log_crédit en niveau


Series: D1_LOG_CREDIT Workfile: UNTITLED::Untitled\

View | Proc | Object | Properties | Print | Name | Freeze | Sample | Genr | Sheet | Graph | Stats | Ident

Phillips-Perron Unit Root Test on D(D1_LOG_CREDIT)

Null Hypothesis: D(D1_LOG_CREDIT) has a unit root
Exogenous: Constant
Bandwidth: 11 (Newey-West automatic) using Bartlett kernel

		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		-32.92842	0.0001
Test critical values:	1% level	-3.600987	
	5% level	-2.935001	
	10% level	-2.605836	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	0.000330
HAC corrected variance (Bartlett kernel)	2.95E-05

Phillips-Perron Test Equation
Dependent Variable: D(D1_LOG_CREDIT,2)
Method: Least Squares
Date: 05/03/26 Time: 19:07
Sample (adjusted): 2015Q4 2025Q4
Included observations: 41 after adjustments

FIGURE 3.20 – log_crédit en 1ère différence

Le log_credit affiche un comportement tout à fait similaire : caractérisé par une tendance marquée lorsqu'il est pris en niveau, il se stabilise instantanément sous sa forme différenciée, réaffirmant son statut de variable intégrée d'ordre 1, soit $I(1)$.

— **la série inflation :**

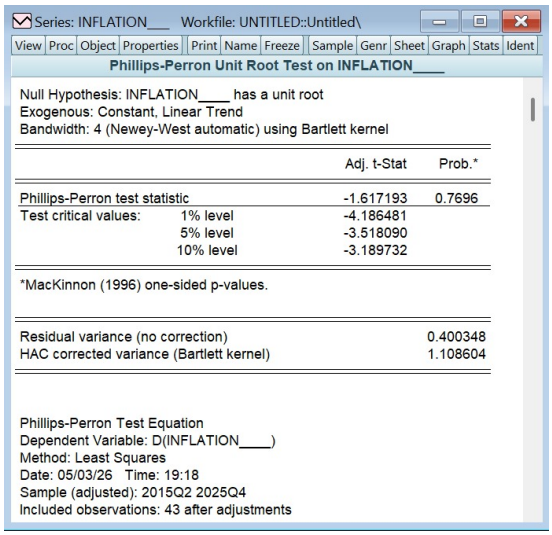


FIGURE 3.21 – inflation en niveau

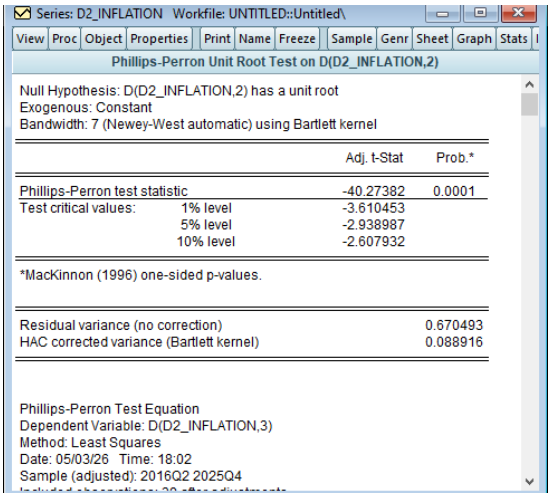


FIGURE 3.22 – inflation en 1ère différence

La série conserve sa non-stationnarité en niveau ainsi qu'en différence première, exigeant une double différenciation pour se stabiliser au seuil de 5 %. Ce constat valide définitivement son statut de processus intégré d'ordre 2, soit $I(2)$.

Ces résultats confirment en tout point les conclusions du test ADF, témoignant d'une parfaite conformité sur l'ordre d'intégration de l'ensemble de nos variables.

Le test de cointégration

Il est nécessaire d'étudier la présence d'une éventuelle relation de cointégration à long terme entre nos variables. Cette analyse exige de travailler sur des séries partageant le même ordre d'intégration. À cet effet, seule l'inflation a fait l'objet d'une transformation en différence première afin de la ramener à ce comportement homogène $I(1)$ et de l'ajuster à cette dynamique commune. Nous testons ainsi la cointégration selon les hypothèses suivantes :
H_0 : Absence de relation de cointégration (les séries ne sont pas cointégrées).
H_1 : Présence d'au moins une relation de cointégration (les séries convergent vers un équilibre de long terme).

La sélection de l'ordre du VAR

Avant de procéder au test de cointégration, il est indispensable de configurer la dynamique de court terme du modèle en déterminant le nombre de retards optimal à partir d'un

modèle VAR.

Lag	LogL	LR	FPE	AIC	SC	HQ
0	119.9144	NA	1.90e-09	-5.893047	-5.679770	-5.816525
1	266.8048	248.5837*	3.71e-12*	-12.14384*	-10.86417*	-11.68470*
2	286.7606	28.65454	5.13e-12	-11.88516	-9.539112	-11.04342
3	307.5386	24.50735	7.61e-12	-11.66865	-8.256212	-10.44429
4	334.3368	24.73683	1.01e-11	-11.76086	-7.282043	-10.15390

TABLE 3.4 – Critères de sélection de l'ordre des retards VAR

Le Tableau 3.4 montre que (AIC) et (SC) convergent à l'unanimité vers le même résultat. Affichant tous deux leurs valeurs minimales au premier retard (indiquées par les astérisques $\star$), ils valident de concert le choix d'un ordre de retard $p = 1$.

Test de Johansen

— **Test de la Trace**

Hypothesized No. of CE(s)	Eigenvalue	Trace Statistic	0.05 Critical Value	Prob.**
None *	0.613611	71.43199	69.81889	0.0370
At most 1	0.327235	32.44463	47.85613	0.5876
At most 2	0.246822	16.19390	29.79707	0.6986
At most 3	0.103354	4.572317	15.49471	0.8524
At most 4	0.002423	0.099478	3.841465	0.7524

TABLE 3.5 – Résultats du test de la trace

— **Test de Maximum Eigenvalue**

Hypothesized No. of CE(s)	Eigenvalue	Max-Eigen Statistic	0.05 Critical Value	Prob.**
None *	0.613611	38.98736	33.87687	0.0112
At most 1	0.327235	16.25074	27.58434	0.6444
At most 2	0.246822	11.62158	21.13162	0.5853
At most 3	0.103354	4.472839	14.26460	0.8064
At most 4	0.002423	0.099478	3.841465	0.7524

TABLE 3.6 – Résultats du test Maximum Eigenvalue

Les tests de la trace (Tableau 3.5) et de la valeur propre maximale (Tableau 3.6) convergent parfaitement. Pour l'hypothèse nulle d'absence de cointégration (None), les p-values (0,0370 et 0,0112) sont inférieures à 5 %, ce qui conduit à son rejet. Pour les lignes suivantes, les probabilités deviennent largement supérieures à 5 %. Ces résultats confirment l'existence d'une unique relation de cointégration à long terme entre nos variables, validant ainsi l'estimation d'un modèle VECM.

3.2.2 Estimation du modèle VECM

Error Correction:	D(LOG_FB...
CointEq1	-1.239561 (0.33353) [-3.71645]
D(LOG_FBCF(-1))	0.427755 (0.25023) [1.70941]
D(LOG_CREDIT(-1))	0.374587 (0.87341) [0.42888]
D(LOG_PIB(-1))	-1.286736 (0.63614) [-2.02271]
D(TAUX_DEBITEUR(-1))	0.097899 (0.06624) [1.47787]
D(D1_INFLATION(-1))	0.008210 (0.02427) [0.33824]
C	0.023360 (0.01422) [1.64294]

TABLE 3.7 – Les coefficients de l'estimation VECM

L'estimation du modèle VECM (présentée ci-dessus) affiche un coefficient de correction d'erreur (CointEq1) égal à $-1,2395$. Ce coefficient, souvent appelé force de rappel, remplit parfaitement les conditions économétriques requises : il est à la fois négatif et hautement significatif (la t-statistique associée de $[-3,71]$ étant supérieure à la valeur critique absolue de $1,96$).

Ce résultat valide définitivement le mécanisme de correction d'erreur et confirme qu'en cas de choc à court terme provoquant un écart par rapport à la trajectoire d'équilibre, le modèle converge naturellement vers sa relation de long terme.

Du côté de la dynamique de court terme, seul le PIB retardé d'une période ($D(LOG_PIB(-1))$) exerce une influence significative à court terme sur l'investissement ($D(LOG_FBCF)$) avec une t-statistique de $[-2, 02]$.

3.2.3 Les tests de diagnostic

Après l'estimation du modèle VECM, il est indispensable de vérifier la validité statistique des résidus. Cette étape de diagnostic permet de s'assurer que les erreurs du modèle constituent un bruit blanc, garantissant ainsi que l'ensemble de l'information dynamique a été correctement capturée et que les estimations ne sont pas biaisées.

Pour ce faire, nous soumettons les résidus du VECM à trois tests statistiques fondamentaux :

Le test d'autocorrélation des résidus

H_0 : Absence d'autocorrélation des résidus.
H_1 : Présence d'autocorrélation des résidus.

Null hypothesis: No serial correlation at lag h

Lag	LRE* stat	df	Prob.	Rao F-stat	df	Prob.
1	22.77262	25	0.5908	0.905898	(25, 94.4)	0.5965

TABLE 3.8 – Résultat du test d'autocorrélation

Les résultats du test LM d'autocorrélation des résidus du VECM révèlent une p-value s'élevant à 0,5908 (colonne Prob), une valeur largement supérieure au seuil critique de 5 %. Par conséquent, nous ne pouvons pas rejeter (H_0) d'absence d'autocorrélation des erreurs au retard 1. Ce résultat confirme la blancheur des résidus et valide la robustesse statistique du modèle estimé.

Le test de normalité (Jarque-Bera)

H_0 : Normalité des résidus (les erreurs suivent une loi normale).
H_1 : Non-normalité des résidus.

Component	Jarque-B...	df	Prob.
1	0.590207	2	0.7445
2	10.74880	2	0.0046
3	19.09166	2	0.0001
4	0.735485	2	0.6923
5	23.26430	2	0.0000
Joint	54.43045	10	0.0000

TABLE 3.9 – Résultat du test de normalité

Les résultats du test de normalité multivarié de Jarque-Bera indiquent une statistique globale de 54,43 associée à une p-value de 0,0000. Cette probabilité étant strictement inférieure au seuil critique de 5 %, nous rejetons H_0 au profit de l'hypothèse alternative (H_1). Les résidus du modèle ne suivent donc pas une loi normale globale, un résultat principalement induit par les composantes 2, 3 et 5 de notre système .

Le test d'hétéroscédasticité des résidus

H_0 : Homoscédasticité des résidus .
H_1 : Hétéroscédasticité des résidus.

Chi-sq	df	Prob.
160.3965	180	0.8503

TABLE 3.10 – Résultat du test d'Hétéroscédasticité

Les résultats du test affichent une statistique du Chi-deux (χ^2) égale à 160,39 associée à une p-value globale de 0,8503. Cette probabilité étant largement supérieure au seuil critique de 5 %, nous acceptons l'hypothèse nulle d'homoscédasticité des résidus. Ce résultat confirme que la variance des erreurs est constante au cours de la période d'étude (2015-2025), ce qui garantit l'efficacité de nos estimateurs et la fiabilité des variances de court terme.

Le test de stabilité du modèle

Afin de finaliser la validation de notre modèle et de s'assurer de sa viabilité dynamique à moyen et long terme, nous procédons au test de stabilité structurelle des racines inverses du polynôme caractéristique AR (couramment appelé test du cercle unité).

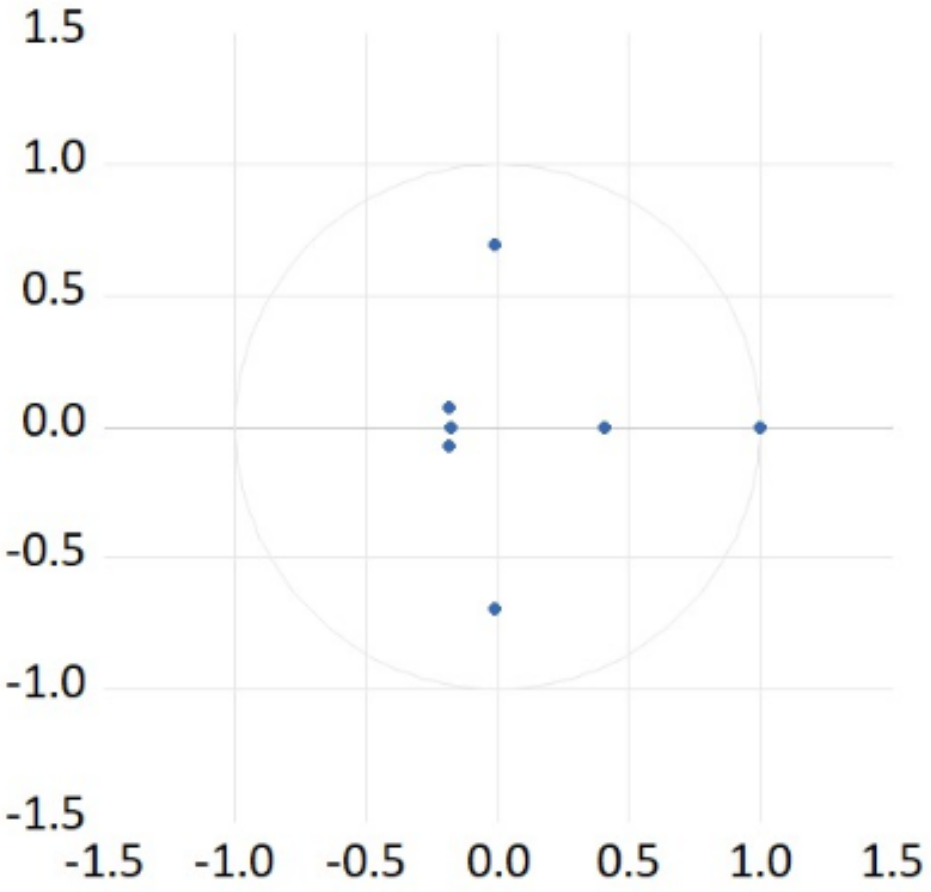


FIGURE 3.23 – Stabilité du modèle

L'interprétation du graphique montre que la condition de stabilité est parfaitement respectée : toutes les racines inverses (représentées par les points bleus) se situent strictement à l'intérieur du cercle unité, ou se trouvent exactement sur sa frontière . Aucun point ne diverge à l'extérieur du cercle de rayon 1.

Ce résultat confirme que notre système dynamique est structurellement stable, convergent, et parfaitement valide pour mener des analyses d'impact par simulations de chocs.

3.3 Prévisions issues du modèle VECM

À la suite du test de stabilité du modèle, cette section est consacrée à la mise en œuvre des prévisions à partir du VECM estimé. L'objectif est de générer des valeurs prédites sur

la période considérée et d'évaluer la performance prédictive du modèle à l'aide de mesures d'erreur appropriées.

3.3.1 Analyse des prédictions sur la période de test historique

Cette sous-section compare les valeurs prédites aux observations réelles sur la période de test afin d'évaluer la performance prédictive du VECM hors échantillon.

2024Q1	11.62482	11.53001
2024Q2	11.61660	11.67018
2024Q3	11.64125	11.74839
2024Q4	11.66249	11.81248
2025Q1	11.66402	11.67825
2025Q2	11.66218	11.82648
2025Q3	11.67235	11.85215
2025Q4	11.68755	11.90695

TABLE 3.11 – Résultats de la prévision VECM

Ce tableau illustre la comparaison entre les prévisions du modèle VECM et les données réelles sur 2024-2025. Les valeurs prévues restent très proches des observations, avec des écarts minimes, ce qui traduit une bonne précision du modèle. On observe tantôt de légères surestimations (ex. 2024Q1), tantôt de petites sous-estimations (ex. 2024Q2), mais globalement la dynamique est bien reproduite, confirmant la pertinence du VECM pour la prévision.

3.3.2 Analyse des Résultats et Performances Comparatives

Les résultats de prévision sont analysés et les performances du modèle sont comparées à l'aide des principales mesures d'erreur afin d'évaluer sa précision et sa robustesse.

	A	B
1	Métrique	Valeur
2	MAE	0.022347
3	RMSE	0.059064

TABLE 3.12 – Résultats des métriques VECM

Ce tableau présente les indicateurs d'évaluation du modèle VECM, à savoir le MAE et le RMSE . Les valeurs obtenues — MAE = 0.0223 et RMSE = 0.0590 — sont très faibles, ce qui traduit une bonne précision du modèle et une capacité à reproduire fidèlement les données réelles. Le MAE indique que l'écart moyen absolu entre prévisions et observations est limité, tandis que le RMSE confirme que les erreurs restent faibles même lorsqu'elles sont amplifiées au carré. Ces résultats renforcent la pertinence du VECM pour la prévision.

3.3.3 Projections Futures pour l'Année 2026

Les projections du modèle VECM pour l'année 2026 sont présentées afin d'anticiper l'évolution future de la variable étudiée.

2026Q1	11.89565
2026Q2	11.90445
2026Q3	11.91626
2026Q4	11.92686

TABLE 3.13 – Projection VECM 2026

Ce tableau présente la projection du modèle VECM pour l'année 2026, trimestre par trimestre. Les valeurs prévues montrent une évolution régulière et légèrement croissante, passant de 11.89 au premier trimestre à 11.92 au quatrième trimestre. Cette progression traduit une tendance stable et ascendante, suggérant que le modèle anticipe une continuité de la dynamique observée précédemment, sans rupture majeure. La projection met ainsi en évidence la capacité du VECM à prolonger les résultats de la période de test vers l'avenir, en fournissant une trajectoire cohérente et réaliste pour l'année 2026.

3.4 Approche Comparative par Machine Learning

Afin de challenger la robustesse de notre modélisation économétrique traditionnelle (VECM), nous introduisons une approche alternative issue de l'apprentissage supervisé : l'algorithme XGBoost (eXtreme Gradient Boosting), mis en concurrence avec le modèle de Random Forest (Forêts Aléatoires)

3.4.1 Transformation des Données en Format Supervisé

Les algorithmes d'apprentissage ne possédant pas de mémoire temporelle native, la série chronologique brute a été transformée en une matrice de données supervisées. Pour un

échantillon total de 44 observations trimestrielles, le passage à une structure en Lag 1 a permis de conserver 43 lignes exploitables, découpées de manière strictement chronologique (Time Series Split) :

— **Échantillon d'Entraînement (Train set) :**35 trimestres (soit environ 81% des données), dédiés à l'apprentissage des structures économiques par les algorithmes.
— **Échantillon de Test (Test set) :**8 trimestres (soit 2 ans d'historique conservés hors d'un accès direct du modèle), dédiés à la validation et à la mesure de la performance prédictive.

3.4.2 Analyse des prédictions sur la période de test historique

Avant de projeter le modèle dans le futur pour l'année 2026, il est fondamental d'évaluer sa capacité à répliquer le passé récent sur l'échantillon de test (trimestres 36 à 43).

```
============================================================
2. PRÉDICTIONS DÉTAILLÉES SUR LA PÉRIODE DE TEST HISTORIQUE
============================================================
 Trimestre  Vraie Valeur (log_fbcf)  Prédit XGBoost  Prédit Random Forest
        36                11.530006       11.571666             11.574878
        37                11.670180       11.571666             11.565178
        38                11.748389       11.571666             11.577746
        39                11.812477       11.481528             11.554421
        40                11.678251       11.453657             11.542446
        41                11.826485       11.447965             11.542446
        42                11.852153       11.447965             11.531086
        43                11.906946       11.447965             11.531086
```

TABLE 3.14 – Les prédictions sur la période de test

Sous-estimation de la tendance : La vraie FBC progresse (de 11,53 à 11,90), mais les deux modèles de Machine Learning échouent à suivre cette croissance et sous-estiment la réalité.

Prédictions figées (Effet de palier) : Les modèles n'évoluent pas de manière fluide et se bloquent sur des valeurs identiques d'un trimestre à l'autre (ex : XGBoost reste scotché à 11,5716 puis à 11,4479).
Cause principale : Les arbres de décision fonctionnent par seuils rigides. Face à des données en logarithmes où les variations sont infimes, les algorithmes restent coincés sur la même décision au lieu de tracer une courbe dynamique.

3.4.3 Analyse des Résultats et Performances Comparatives

Après alignement des modèles sur les données du HCP, les performances mesurées sur l'échantillon de test hors-apprentissage sont résumées dans le tableau suivant :

```
============================================================
1. TABLEAU COMPARATIF DES PERFORMANCES (SUR JEU DE TEST)
============================================================
                    Métrique XGBoost Random Forest
   RMSE (Erreur quadratique)  0.3000        0.2378
MAE (Erreur absolue moyenne)  0.2643        0.2119
```

TABLE 3.15 – Tableau comparatif des performances

L'analyse des critères d'erreur montre que le modèle Random Forest surpasse XGBoost sur cet échantillon, affichant un RMSE (0,2378) et un MAE (0,2119) plus faibles.

3.4.4 Projections Futures pour l'Année 2026

La génération des trajectoires prédictives pour les quatre trimestres de l'exercice 2026 a été réalisée selon une approche récursive (où la prévision réinjectée à t sert de retard $t-1$ pour le calcul à $t+1$). Les résultats en logarithmes se présentent comme suit :

```
============================================================
3. PROJECTIONS ET PRÉVISIONS DU FUTUR POUR L'ANNÉE 2026
============================================================
Trimestre Prévision XGBoost (log_fbcf) Prévision Random Forest (log_fbcf)
   2026Q1                     11.4480                          11.5311
   2026Q2                     11.4480                          11.5167
   2026Q3                     11.4480                          11.5182
   2026Q4                     11.4480                          11.5182
```

TABLE 3.16 – Prévision pour l'année 2026

On observe une convergence immédiate du modèle XGBoost vers une constante prédictive de 11,4480. Ce phénomène s'explique par la nature discrète des fonctions d'activation par paliers des arbres de décision. En l'absence de chocs macroéconomiques majeurs simulés sur les variables exogènes, le modèle atteint un point fixe stationnaire.

3.5 Personnalisation

Afin de rendre l'exploitation des modèles de prévision plus intuitive et interactive, nous avons développé une interface graphique à l'aide de Streamlit, permettant à l'utilisateur de paramétrer les prévisions, visualiser les résultats et comparer les performances des différents modèles. Les captures d'écran suivantes présentent les principales fonctionnalités de l'application.

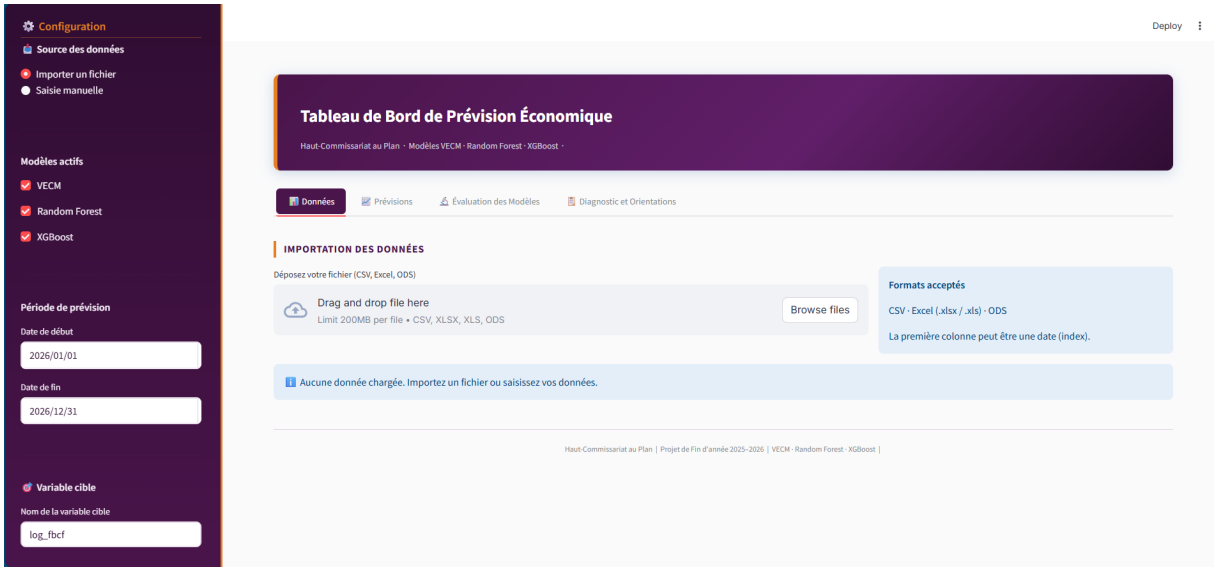


FIGURE 3.24 – Configuration et importation



FIGURE 3.25 – Visualisation des prévisions

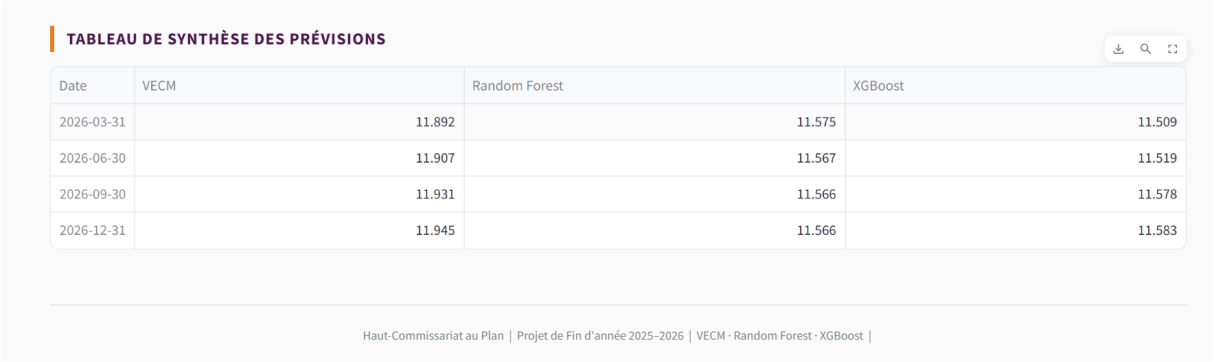


TABLEAU DE SYNTHÈSE DES PRÉVISIONS

Date	VECM	Random Forest	XGBoost
2026-03-31	11.892	11.575	11.509
2026-06-30	11.907	11.567	11.519
2026-09-30	11.931	11.566	11.578
2026-12-31	11.945	11.566	11.583

Haut-Commissariat au Plan | Projet de Fin d'année 2025–2026 | VECM · Random Forest · XGBoost |

FIGURE 3.26 – Tableau des prévisions



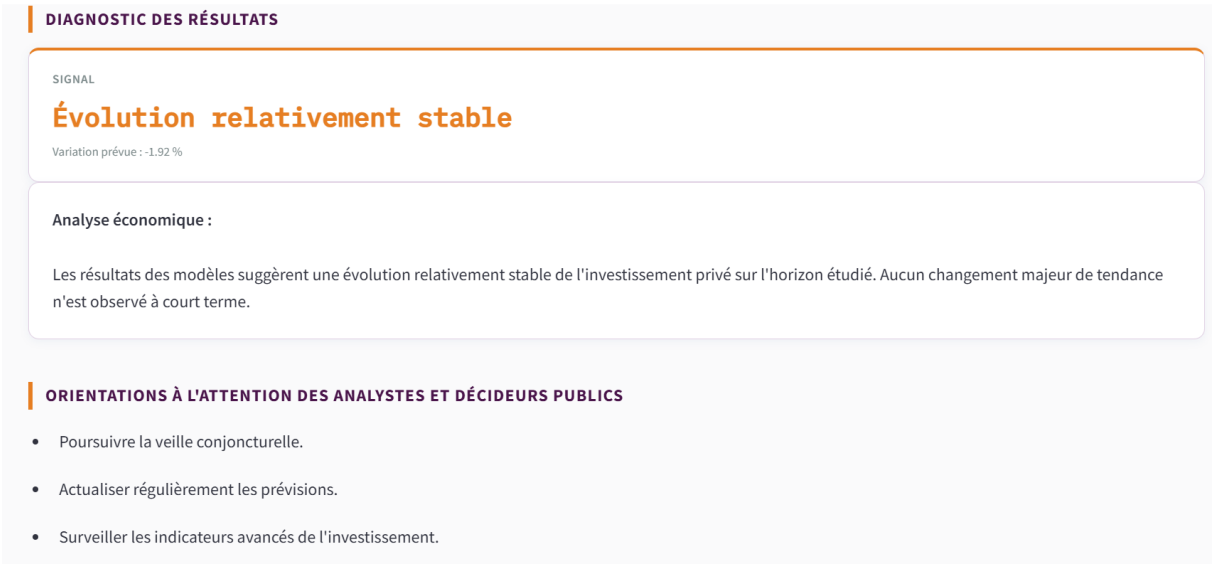
Données | Prévisions | Évaluation des Modèles | Diagnostic et Orientations

MÉTRIQUES COMPARATIVES

Modèle	MAE	RMSE
VECM	0.215060	0.229890
Random Forest	0.191410	0.212770
XGBoost	0.233710	0.262420

Haut-Commissariat au Plan | Projet de Fin d'année 2025–2026 | VECM · Random Forest · XGBoost |

FIGURE 3.27 – Tableau des métriques



DIAGNOSTIC DES RÉSULTATS

SIGNAL

Évolution relativement stable

Variation prévue : -1.92 %

Analyse économique :

Les résultats des modèles suggèrent une évolution relativement stable de l'investissement privé sur l'horizon étudié. Aucun changement majeur de tendance n'est observé à court terme.

ORIENTATIONS À L'ATTENTION DES ANALYSTES ET DÉCIDEURS PUBLICS

- Poursuivre la veille conjoncturelle.
- Actualiser régulièrement les prévisions.
- Surveiller les indicateurs avancés de l'investissement.

FIGURE 3.28 – Diagnostic et orientations

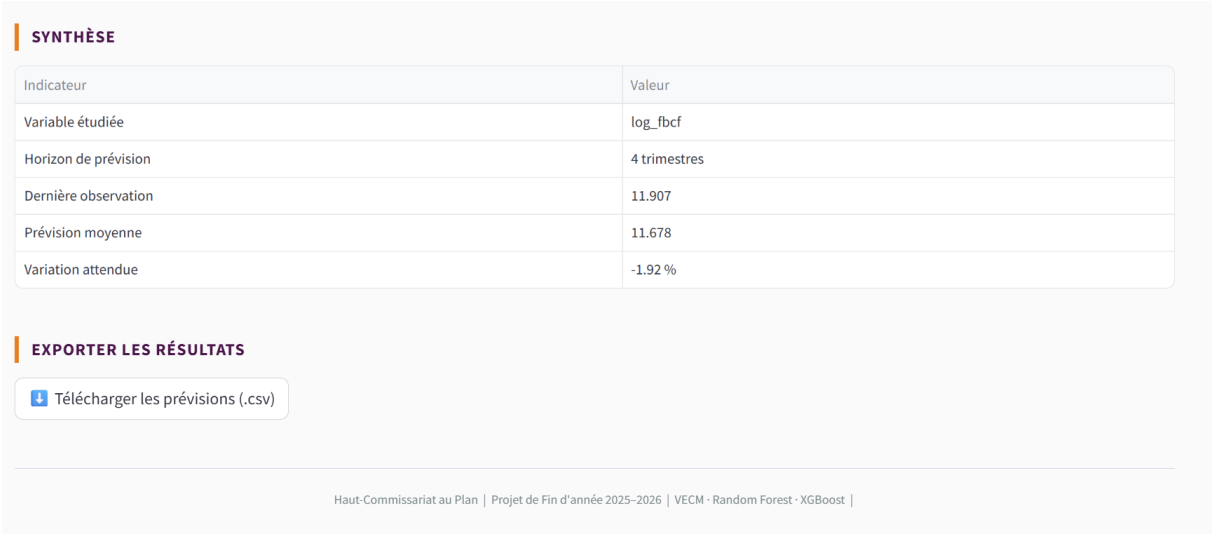


FIGURE 3.29 – Synthèse et exportation

3.6 Conclusion

En conclusion, ce chapitre pratique a permis de valider notre démarche empirique à travers deux apports clés : d'une part, la démonstration de la complémentarité entre la modélisation économétrique (VECM) et le Machine Learning (Random Forest / XGBoost),et d'autre part,le développement d'une interface applicative dédiée pour automatiser l'analyse.

Conclusion générale

Au terme de ce travail réalisé au sein du Haut-Commissariat au Plan, nous avons étudié la modélisation et la prévision de la Formation Brute de Capital privée au Maroc. L'objectif principal était de comparer les performances des approches économétriques traditionnelles et des techniques de Machine Learning dans l'analyse de l'investissement privé.

Sur le plan méthodologique, le modèle à Vecteur à Correction d'Erreur (VECM) a permis de mettre en évidence une relation de long terme entre l'investissement privé et ses principaux déterminants macroéconomiques. En parallèle, les modèles XGBoost et Random Forest ont été utilisés comme outils de comparaison.

Les résultats obtenus montrent que, bien que les modèles de Machine Learning soient performants pour reproduire les dynamiques observées dans les données historiques, ils présentent des limites en matière d'extrapolation. À l'inverse, le VECM s'est révélé plus adapté à la projection des tendances futures et à la simulation de scénarios économiques, grâce à son ancrage théorique.

Dans une optique de valorisation des résultats obtenus, une interface interactive développée sous Streamlit a été mise en place afin de rendre les analyses et les simulations plus accessibles et intuitives.Au-delà des résultats obtenus, plusieurs perspectives peuvent être envisagées, notamment l'intégration de nouvelles variables économiques, l'actualisation automatique des données, ainsi que le développement de modèles hybrides combinant la rigueur théorique du VECM et les capacités prédictives du Machine Learning. Ces améliorations pourraient contribuer à renforcer la précision des prévisions et à enrichir les analyses futures de l'investissement privé au Maroc.

Bibliographie

[1] -Mme.Hadiri. – *Support de cours d'Économétrie*, ENSA Agadir.

[2] -M.El Asri. – *Support de cours sur les Processus Stochastiques*, ENSA Agadir.

[3] -M. Ludkovski. – *Statistical Machine Learning for Quantitative Finance*, Annual Review of Statistics and Its Application.

[4] -M.Qazdar. – *Support de cours de Data Science*, ENSA Agadir.

[5] -Haut-Commissariat au Plan (HCP). – *Budget Économique Prévisionnel 2026.*

[6] -Mme.Essalhi & M.Salah Eddine. – *L'impact de la politique monétaire sur l'investissement privé au Maroc.*

[7] -Bank Al-Maghrib. – *Rapports annuels et études économiques.*

Webographie

[1] -Haut-Commissariat au Plan (HCP) – `www.hcp.ma`

[2] -Bank Al-Maghrib – `www.bkam.ma`