المدرسة الوطنية للعلوم التطبيقية -أكادير
ⵜⵉⵎⵙⵙⵓⵜ ⵏ ⵜⵓⵙⵙⵓⵔⵉⵏ ⵜⵉⵖⵓⵔⵉⵖⵉ – ⴰⵣⴰⵏⵓ.
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES - AGADIR

Rapport du Projet

Pricing d'Options Européennes

Approches Analytique, Numérique et Machine Learning

Présenté par :

EL IDRISSI Salma

Encadre par :

M. B .EL ASRI

Filière : Finance et Ingénierie Décisionnelle

Année universitaire : 2025–2026

Résumé

Ce rapport présente une étude comparative et rigoureuse du pricing d'options européennes en combinant trois familles d'approches complémentaires.

La **première partie** établit le cadre théorique via le modèle de Black-Scholes (1973), qui fournit une solution analytique fermée à l'équation différentielle stochastique gouvernant la dynamique du sous-jacent sous l'hypothèse de mouvement brownien géométrique. Les lettres grecques (Δ, Γ, Θ, ν, ρ), la parité put-call et la volatilité implicite par Newton-Raphson complètent ce cadre de référence.

La **deuxième partie** introduit les méthodes numériques : le schéma d'Euler-Maruyama pour la discrétisation de l'EDS et la méthode de Monte Carlo pour l'estimation des prix par simulation. L'impact du pas de temps Δt et du nombre de simulations N sur la précision et la convergence est analysé quantitativement.

La **troisième partie** explore l'apprentissage automatique (MLP, Gradient Boosting) comme approximateur de la fonction de pricing, à partir d'un dataset synthétique généré via Black-Scholes.

Enfin, une **comparaison globale** est réalisée en termes d'erreur, de vitesse de calcul, de stabilité et de domaine d'application, matérialisée dans un **dashboard interactif Streamlit**.

Mots-clés : Options européennes, Black-Scholes, Monte Carlo, Euler-Maruyama, Machine Learning, Greeks, Volatilité implicite, Dashboard Streamlit.

Table des matières

Résumé **i**

Introduction Générale **1**

1 Fondements Théoriques des Marchés Financiers et des Options **3**

1.1 Notions de Base sur les Marchés Financiers 3

1.1.1 Actifs Financiers et Sous-jacents 3

1.1.2 Hypothèses de Marché Idéal 3

1.2 Les Options Financières 4

1.2.1 Paramètres Fondamentaux 4

1.2.2 La Moneyness 4

2 Le Modèle de Black-Scholes : Cadre Mathématique **6**

2.1 Le Mouvement Brownien et le Calcul d'Itô 6

2.1.1 Lemme d'Itô 6

2.2 Le Mouvement Brownien Géométrique (GBM) 7

2.2.1 Solution Explicite du GBM 7

2.3 L'Équation de Black-Scholes 7

2.3.1 Le Portefeuille de Couverture Autofinançant 8

2.3.2 La Mesure Risque-Neutre 8

2.4 La Formule de Black-Scholes 8

2.4.1 Interprétation Probabiliste 9

2.5 La Volatilité Implicite 9

3 Méthodes Numériques : Euler-Maruyama et Monte Carlo **10**

3.1 Le Schéma d'Euler-Maruyama 10

3.1.1 Motivation 10

3.1.2 Discrétisation de l'EDS 10

3.1.3 Schéma Log-Euler (Euler Exponentiel) 10

3.1.4 Algorithme d'Euler-Maruyama 11

3.1.5 Étude de la Convergence en Δt 11
3.2 La Méthode de Monte Carlo 12
3.2.1 Principe Général 12
3.2.2 Propriétés Statistiques de l'Estimateur 12
3.2.3 Erreur Standard et Intervalle de Confiance 13
3.2.4 Réduction de Variance : Variables Antithétiques 13
3.2.5 Convergence Empirique 14

4 Apprentissage Automatique pour le Pricing d'Options 15
4.1 Motivation et Cadre du Problème ML 15
4.2 Construction du Dataset 15
4.2.1 Génération Synthétique 15
4.2.2 Partitionnement des Données 16
4.3 Modèle de Machine Learning 16
4.3.1 Gradient Boosting Regressor (GBR) 16
4.4 Métriques d'Évaluation 17
4.5 Résultats et Analyse 17

5 Comparaison Globale et Dashboard Streamlit 19
5.1 Tableau Comparatif Général 20
5.2 Analyse des Erreurs 20
5.2.1 Black-Scholes comme Référence 21
5.2.2 Erreur Monte Carlo 21
5.2.3 Erreur Euler-Maruyama 21
5.2.4 Erreur ML 21
5.3 Description du Dashboard Streamlit 21
5.3.1 Architecture de l'Application 21
5.3.2 Composants Interactifs 22
5.3.3 Bibliothèques Utilisées 22
5.4 Extrait de l'interface 23

Conclusion Générale 24

Bibliographie 26

A Rappels Mathématiques 27
A.1 La Loi Log-Normale 27
A.2 Le Théorème de Girsanov 27

Introduction Générale

Les marchés financiers contemporains reposent sur une infrastructure quantitative d'une complexité croissante. Au cœur de cette infrastructure se trouvent les **produits dérivés**, dont les *options* constituent la famille la plus répandue et la plus étudiée. Une option est un contrat qui confère à son détenteur le droit mais non l'obligation d'acheter (option *call*) ou de vendre (option *put*) un actif sous-jacent à un prix convenu appelé *prix d'exercice* K, à une date future dite *maturité* T.

La question centrale du **pricing** c'est-à-dire la détermination du juste prix de ce droit constitue l'un des problèmes fondamentaux de la finance quantitative. Avant la révolution de Black, Scholes en 1973, ce problème était abordé de manière largement empirique. La formule de Black-Scholes, en modélisant le sous-jacent comme un mouvement brownien géométrique et en invoquant un argument d'absence d'arbitrage, a fourni pour la première fois une solution analytique exacte pour les options européennes. Cet apport a valu à Robert et Myron Scholes le Prix Nobel d'Économie en 1997.

Cependant, les hypothèses du modèle de Black-Scholes , volatilité constante, taux d'intérêt constant, marché parfaitement liquide, continuité des échanges sont rarement vérifiées en pratique. Dès lors, deux familles de méthodes alternatives se sont développées :

1. **Les méthodes numériques** : simulations de Monte Carlo, schémas de discrétisation des équations différentielles stochastiques (EDS), arbres binomiaux, différences finies, etc.
2. **Les méthodes d'apprentissage automatique** : approximation de la fonction de pricing par des réseaux de neurones, des forêts aléatoires, des modèles de gradient boosting, etc.

Problématique

Face à cette pluralité de méthodes, une question naturelle émerge :

> *Dans quelle mesure les méthodes numériques et les approches de machine learning permettent-elles d'approcher le prix analytique de Black-Scholes pour les options européennes, et quels sont leurs compromis respectifs en termes de précision, de vitesse de calcul, de stabilité et d'applicabilité ?*

Objectifs du Projet

Ce projet poursuit les objectifs suivants :

1. Établir rigoureusement le cadre théorique du modèle de Black-Scholes et dériver la formule analytique pour les options européennes.
2. Implémenter et analyser le schéma d'Euler-Maruyama pour la simulation de trajectoires du sous-jacent, en étudiant l'impact du pas de temps Δt.
3. Mettre en œuvre la méthode de Monte Carlo et analyser sa convergence en $\mathcal{O}(1/\sqrt{N})$ en fonction du nombre de simulations.
4. Construire un dataset synthétique et entraîner des modèles de machine learning (MLP, GBR, RF) capables d'approcher la fonction de pricing.
5. Réaliser une comparaison globale rigoureuse de toutes ces approches et développer un dashboard interactif Streamlit.

CHAPITRE 1

Fondements Théoriques des Marchés Financiers et des Options

1.1 Notions de Base sur les Marchés Financiers

1.1.1 Actifs Financiers et Sous-jacents

Un **actif financier** est un titre représentant un droit sur des flux de trésorerie futurs. Dans le cadre du pricing d'options, l'actif de référence est appelé *sous-jacent* et noté S. Il peut s'agir d'une action, d'un indice boursier, d'une devise, d'une matière première, ou d'un taux d'intérêt.

Le sous-jacent évolue de manière aléatoire au cours du temps. Sa dynamique est modélisée dans un espace probabilisé filtré $(\Omega, \mathcal{F}, (\mathcal{F}_t)_{t\geq 0}, \mathbb{P})$, où $\mathbb{P}$ désigne la *mesure de probabilité historique*.

1.1.2 Hypothèses de Marché Idéal

Les modèles standards de pricing supposent un marché idéal vérifiant :

— **Absence d'opportunité d'arbitrage (AOA)** : il n'existe pas de stratégie autofinançante permettant de réaliser un profit certain sans risque.

— **Complétude** : tout actif contingent est réplicable par un portefeuille d'actifs de base.

— **Divisibilité et liquidité** : les actifs peuvent être achetés et vendus en toute quantité à tout instant.

— **Absence de coûts de transaction** et **taux sans risque** r **constant**.

1.2 Les Options Financières

Définition 1.1— Option Financière

Une option européenne est un contrat donnant à son détenteur le droit, mais non l'obligation, d'acheter (option *call*) ou de vendre (option *put*) un actif sous-jacent au prix d'exercice K à la date de maturité T.

Le **payoff** à maturité est :

$$\Pi_{\text{call}} = \max(S_T - K,\ 0) = (S_T - K)^+ \tag{1.1}$$

$$\Pi_{\text{put}} = \max(K - S_T,\ 0) = (K - S_T)^+ \tag{1.2}$$

1.2.1 Paramètres Fondamentaux

TABLE 1.1 – Paramètres du modèle de pricing

Symbole	Description
S_0	Prix spot (actuel) du sous-jacent
K	Prix d'exercice (strike)
T	Maturité en années
r	Taux sans risque (annualisé, continu)
σ	Volatilité annualisée du sous-jacent
C	Prix du call européen
P	Prix du put européen

1.2.2 La Moneyness

On caractérise la position de l'option par rapport au marché via la *moneyness* $m = S_0/K$:

— $m > 1$: option *dans la monnaie* (**ITM** — In The Money)

— $m \approx 1$: option *à la monnaie* (**ATM** — At The Money)

— $m < 1$: option *hors de la monnaie* (**OTM** — Out of The Money)

Parité Put-Call

Théorème 1.1— Parité Put-Call

Pour des options européennes sur le même sous-jacent, au même strike K et à la même maturité T, la relation de parité put-call s'écrit :

$$C - P = S_0 - Ke^{-rT}$$

Cette relation est une conséquence directe de l'hypothèse d'absence d'arbitrage. Elle permet de déduire le prix d'un put à partir du prix d'un call, et inversement.

Démonstration (argument d'arbitrage) : Considérons deux portefeuilles à la date $t = 0$:

— **Portefeuille A** : Long call $C + Ke^{-rT}$ investi au taux r.

— **Portefeuille B** : Long put P + Long 1 action S_0.

À maturité T, les deux portefeuilles ont la même valeur $\max(S_T, K)$. Par AOA : $C + Ke^{-rT} = P + S_0$. □ ce qui donne la relation du parité put-call suivante :

$$C - P = S_0 - Ke^{-rT}$$

CHAPITRE 2

Le Modèle de Black-Scholes : Cadre Mathématique

2.1 Le Mouvement Brownien et le Calcul d'Itô

Définition 2.1— Mouvement Brownien Standard

Un processus stochastique $(W_t)_{t\geq 0}$ est appelé *mouvement brownien standard* (ou processus de Wiener) s'il vérifie :

(i) $W_0 = 0$ presque sûrement ;

(ii) Les accroissements sont *indépendants* : pour $0 \leq s < t$, $W_t - W_s$ est indépendant de $\mathcal{F}_s$;

(iii) Les accroissements sont *gaussiens stationnaires* : $W_t - W_s \sim \mathcal{N}(0, t-s)$;

(iv) Les trajectoires sont continues presque sûrement.

2.1.1 Lemme d'Itô

Théorème 2.1— Lemme d'Itô (version unidimensionnelle)

Soit (X_t) un processus d'Itô vérifiant $\mathrm{d}X_t = \mu_t\,\mathrm{d}t + \sigma_t\,\mathrm{d}W_t$, et soit $f(t,x)$ une fonction de classe $\mathcal{C}^{1,2}$. Alors :

$$\mathrm{d}f(t,X_t) = \frac{\partial f}{\partial t}\,\mathrm{d}t + \frac{\partial f}{\partial x}\,\mathrm{d}X_t + \frac{1}{2}\frac{\partial^2 f}{\partial x^2}(\mathrm{d}X_t)^2$$

où l'on utilise la règle $(\mathrm{d}W_t)^2 = \mathrm{d}t$, $\mathrm{d}t \cdot \mathrm{d}W_t = 0$.

De manière explicite :

$$\mathrm{d}f = \left(\frac{\partial f}{\partial t} + \mu_t \frac{\partial f}{\partial x} + \frac{\sigma_t^2}{2}\frac{\partial^2 f}{\partial x^2}\right)\mathrm{d}t + \sigma_t \frac{\partial f}{\partial x}\,\mathrm{d}W_t$$

2.2 Le Mouvement Brownien Géométrique (GBM)

Définition 2.2— GBM — Équation Différentielle Stochastique

Sous la mesure historique $\mathbb{P}$, le prix du sous-jacent suit le **Mouvement Brownien Géométrique** :

$$\mathrm{d}S_t = \mu S_t\,\mathrm{d}t + \sigma S_t\,\mathrm{d}W_t \tag{2.1}$$

où μ est le taux de dérive (rendement espéré) et $\sigma > 0$ la volatilité.

2.2.1 Solution Explicite du GBM

Appliquons le lemme d'Itô à $f(t, S_t) = \ln S_t$. On a :

$$\frac{\partial f}{\partial t} = 0, \quad \frac{\partial f}{\partial S} = \frac{1}{S}, \quad \frac{\partial^2 f}{\partial S^2} = -\frac{1}{S^2}$$

D'où :

$$\mathrm{d}(\ln S_t) = \left(\mu - \frac{\sigma^2}{2}\right)\mathrm{d}t + \sigma\,\mathrm{d}W_t$$

Par intégration entre 0 et T :

$$\boxed{S_T = S_0 \exp\left[\left(\mu - \frac{\sigma^2}{2}\right)T + \sigma W_T\right]} \tag{2.2}$$

Puisque $W_T \sim \mathcal{N}(0, T)$, on en déduit que $\ln S_T$ est gaussien :

$$\ln S_T \sim \mathcal{N}\left(\ln S_0 + \left(\mu - \frac{\sigma^2}{2}\right)T,\ \sigma^2 T\right)$$

2.3 L'Équation de Black-Scholes

2.3.1 Le Portefeuille de Couverture Autofinançant

Considérons un portefeuille $\Pi_t = V_t - \Delta_t S_t$ composé d'une option de valeur $V(t, S_t)$ et d'une position courte Δ_t sur le sous-jacent. Par application du lemme d'Itô à $V(t, S_t)$:

$$\mathrm{d}V = \left(\frac{\partial V}{\partial t} + \mu S \frac{\partial V}{\partial S} + \frac{\sigma^2 S^2}{2} \frac{\partial^2 V}{\partial S^2} \right) \mathrm{d}t + \sigma S \frac{\partial V}{\partial S} \, \mathrm{d}W_t$$

En choisissant le **delta de couverture** $\Delta_t = \dfrac{\partial V}{\partial S}$, le terme stochastique $\mathrm{d}W_t$ disparaît du portefeuille Π_t, qui devient alors sans risque :

$$\mathrm{d}\Pi_t = \left(\frac{\partial V}{\partial t} + \frac{\sigma^2 S^2}{2} \frac{\partial^2 V}{\partial S^2} \right) \mathrm{d}t$$

L'absence d'arbitrage impose $\mathrm{d}\Pi_t = r \Pi_t \, \mathrm{d}t$, ce qui conduit à :

Résultat Clé

Équation aux Dérivées Partielles de Black-Scholes :

$$\frac{\partial V}{\partial t} + r S \frac{\partial V}{\partial S} + \frac{\sigma^2 S^2}{2} \frac{\partial^2 V}{\partial S^2} - r V = 0 \tag{2.3}$$

avec la condition terminale $V(T, S) = \max(S - K, 0)$ pour un call.

2.3.2 La Mesure Risque-Neutre

Par le théorème de Girsanov, il existe une mesure de probabilité $\mathbb{Q}$ (dite *risque-neutre* ou *martingale équivalente*) sous laquelle le prix actualisé du sous-jacent est une martingale, et le GBM devient :

$$\mathrm{d}S_t = r S_t \, \mathrm{d}t + \sigma S_t \, \mathrm{d}\widetilde{W}_t^{\mathbb{Q}} \tag{2.4}$$

où $\widetilde{W}^{\mathbb{Q}}$ est un mouvement brownien sous $\mathbb{Q}$.

Sous $\mathbb{Q}$, le prix de l'option est :

$$V(t, S_t) = e^{-r(T-t)} \, \mathbb{E}^{\mathbb{Q}}[\text{payoff}(S_T) \mid \mathcal{F}_t]$$

2.4 La Formule de Black-Scholes

La résolution de l'EDP (2.3) avec les conditions aux limites appropriées donne la **formule analytique de Black-Scholes** :

Théorème 2.2— Formule de Black-Scholes (1973)

Le prix d'une option européenne call (resp. put) de maturité T, de strike K, sur un sous-jacent de prix spot S_0, de volatilité σ et pour un taux sans risque r est :

$$C = S_0 \mathcal{N}(d_1) - K e^{-rT} \mathcal{N}(d_2) \tag{2.5}$$

$$P = K e^{-rT} \mathcal{N}(-d_2) - S_0 \mathcal{N}(-d_1) \tag{2.6}$$

où $\mathcal{N}(\cdot)$ est la fonction de répartition de la loi normale standard, et :

$$d_1 = \frac{\ln(S_0/K) + \left(r + \dfrac{\sigma^2}{2}\right) T}{\sigma\sqrt{T}}, \qquad d_2 = d_1 - \sigma\sqrt{T} \tag{2.7}$$

2.4.1 Interprétation Probabiliste

Sous la mesure risque-neutre $\mathbb{Q}$:

— $\mathcal{N}(d_2) = \mathbb{Q}(S_T > K)$: probabilité risque-neutre que l'option expire dans la monnaie.

— $\mathcal{N}(d_1)$: sensibilité du prix à la variation du spot (le delta Δ).

— $Ke^{-rT}\mathcal{N}(d_2)$: valeur actualisée du strike payé si l'option est exercée.

— $S_0\mathcal{N}(d_1)$: espérance actualisée risque-neutre de S_T conditionnellement à l'exercice.

2.5 La Volatilité Implicite

La **volatilité implicite** $\hat{\sigma}$ est la valeur de σ qui, insérée dans la formule de Black-Scholes, redonne le prix de marché observé V^{mkt} :

$$\text{BS}(S_0, K, T, r, \hat{\sigma}) = V^{\text{mkt}}$$

Il n'existe pas de formule fermée pour $\hat{\sigma}$. On l'obtient numériquement par la méthode de **Newton-Raphson** :

$$\hat{\sigma}_{n+1} = \hat{\sigma}_n - \frac{\text{BS}(\hat{\sigma}_n) - V^{\text{mkt}}}{\nu(\hat{\sigma}_n)} \tag{2.8}$$

où $\nu(\sigma) = \dfrac{\partial \text{BS}}{\partial \sigma}$ est le vega. Cette méthode converge en moins de 20 itérations en pratique.

CHAPITRE 3

Méthodes Numériques : Euler-Maruyama et Monte Carlo

3.1 Le Schéma d'Euler-Maruyama

3.1.1 Motivation

Le modèle de Black-Scholes possède une solution analytique. Cependant, pour des modèles plus complexes (Heston, SABR, modèles à sauts), aucune formule fermée n'existe. Il est alors nécessaire de *discrétiser* l'EDS et de simuler numériquement les trajectoires.

3.1.2 Discrétisation de l'EDS

Considérons l'EDS du GBM sous la mesure risque-neutre :

$$\mathrm{d}S_t = rS_t\,\mathrm{d}t + \sigma S_t\,\mathrm{d}W_t$$

On partitionne $[0,T]$ en N intervalles de taille $\Delta t = T/N$. Le **schéma d'Euler-Maruyama** approxime $S_{t_{n+1}}$ par :

$$S_{t_{n+1}} = S_{t_n} + rS_{t_n}\Delta t + \sigma S_{t_n}\sqrt{\Delta t}\,Z_n, \quad Z_n \sim \mathcal{N}(0,1) \text{ i.i.d.} \tag{3.1}$$

3.1.3 Schéma Log-Euler (Euler Exponentiel)

Pour le GBM, on préfère appliquer Euler à $\ln S_t$ afin d'assurer la positivité des prix simulés. On obtient le schéma **log-Euler** :

$$\boxed{S_{t_{n+1}} = S_{t_n} \exp\left[\left(r - \frac{\sigma^2}{2}\right)\Delta t + \sigma\sqrt{\Delta t}\, Z_n\right]} \tag{3.2}$$

Ce schéma est en fait **exact** pour le GBM car la solution explicite (2.2) a précisément cette forme.

Remarque 3.1— Erreur de Discrétisation

Pour une EDS générale $\mathrm{d}X_t = a(X_t)\,\mathrm{d}t + b(X_t)\,\mathrm{d}W_t$, le schéma d'Euler-Maruyama produit une erreur de discrétisation d'ordre :

$$\mathbb{E}\Big[\big|X_T - \hat{X}_T\big|\Big] = \mathcal{O}(\Delta t) \quad \text{(convergence forte d'ordre } \tfrac{1}{2}\text{)}$$

$$\Big|\mathbb{E}[f(\hat{X}_T)] - \mathbb{E}[f(X_T)]\Big| = \mathcal{O}(\Delta t) \quad \text{(convergence faible d'ordre 1)}$$

3.1.4 Algorithme d'Euler-Maruyama

Algorithme 3.1— Simulation Euler-Maruyama pour le Pricing

1. **Entrées** : $S_0, K, T, r, \sigma, N_{\text{steps}}, N_{\text{paths}}$
2. Poser $\Delta t \leftarrow T/N_{\text{steps}}$
3. Pour $i = 1, \ldots, N_{\text{paths}}$:
   a. Poser $S_0^{(i)} \leftarrow S_0$
   b. Pour $n = 0, \ldots, N_{\text{steps}} - 1$:
      Tirer $Z_n \sim \mathcal{N}(0,1)$, puis
      $S_{n+1}^{(i)} = S_n^{(i)} \cdot \exp\Big[(r - \sigma^2/2)\Delta t + \sigma\sqrt{\Delta t}\, Z_n\Big]$
   c. Calculer le payoff : $\pi^{(i)} = (S_{N_{\text{steps}}}^{(i)} - K)^+$
4. Prix estimé : $\hat{C} = e^{-rT} \cdot \dfrac{1}{N_{\text{paths}}} \displaystyle\sum_{i=1}^{N_{\text{paths}}} \pi^{(i)}$

3.1.5 Étude de la Convergence en Δt

Afin d'étudier empiriquement l'impact du pas de temps, on fait varier $N_{\text{steps}} \in \{5, 10, 20, 50, 100, 252, 500$ et on compare le prix Euler au prix Black-Scholes de référence. Le tableau suivant illustre les résultats obtenus pour $S_0 = 100$, $K = 100$, $T = 1$, $r = 5\%$, $\sigma = 20\%$, $N_{\text{paths}} = 3\,000$.

TABLE 3.1 – Impact du pas de temps sur la précision du schéma d'Euler (exemple numérique)

N_{steps}	Δt	Prix Euler	|Erreur vs BS|	Erreur (%)
5	0.20000	≈ 10.350	≈ 0.098	≈ 0.94
10	0.10000	≈ 10.290	≈ 0.038	≈ 0.37
50	0.02000	≈ 10.260	≈ 0.008	≈ 0.08
100	0.01000	≈ 10.255	≈ 0.003	≈ 0.03
252	0.00397	≈ 10.253	≈ 0.001	≈ 0.01

On observe que l'erreur décroît avec Δt, confirmant la convergence de l'ordre $\mathcal{O}(\Delta t)$ attendue.

3.2 La Méthode de Monte Carlo

3.2.1 Principe Général

La méthode de Monte Carlo exploite la loi des grands nombres pour estimer l'espérance d'une variable aléatoire par la moyenne de N réalisations indépendantes. Pour le pricing :

$$C = e^{-rT}\,\mathbb{E}^{\mathbb{Q}}\Big[(S_T - K)^+\Big] \approx e^{-rT} \cdot \frac{1}{N}\sum_{i=1}^{N}(S_T^{(i)} - K)^+ = \hat{C}_N$$

La solution exacte du GBM permet de simuler directement S_T **sans discrétisation intermédiaire** :

$$\boxed{S_T^{(i)} = S_0 \exp\left[\left(r - \frac{\sigma^2}{2}\right)T + \sigma\sqrt{T}\,Z^{(i)}\right], \quad Z^{(i)} \sim \mathcal{N}(0,1)} \tag{3.3}$$

3.2.2 Propriétés Statistiques de l'Estimateur

Proposition 3.1— Estimateur MC — Biais et Variance

L'estimateur Monte Carlo $\hat{C}_N$ est :

— **Sans biais** : $\mathbb{E}[\hat{C}_N] = C$

— **Convergent** (LGN) : $\hat{C}_N \xrightarrow{p.s.} C$

— **Asymptotiquement normal** (TCL) : $\sqrt{N}(\hat{C}_N - C) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma_\pi^2)$

où $\sigma_\pi^2 = \mathrm{Var}\left[e^{-rT}(S_T - K)^+\right]$.

3.2.3 Erreur Standard et Intervalle de Confiance

$$\widehat{\mathrm{SE}} = \frac{e^{-rT} \cdot \hat{\sigma}_\pi}{\sqrt{N}}, \quad \hat{\sigma}_\pi = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}\left(\pi^{(i)} - \bar{\pi}\right)^2}$$

L'intervalle de confiance à 95% est :

$$\hat{C}_N \pm 1.96 \times \widehat{\mathrm{SE}} \tag{3.4}$$

Le taux de convergence est $\mathcal{O}(1/\sqrt{N})$, indépendamment de la dimension du problème.

3.2.4 Réduction de Variance : Variables Antithétiques

L'idée est de simuler des paires $(Z, -Z)$ corrélées négativement, ce qui réduit la variance de l'estimateur :

$$\hat{C}_{\mathrm{anti}} = \frac{e^{-rT}}{2N}\sum_{i=1}^{N}\left[\pi(Z^{(i)}) + \pi(-Z^{(i)})\right]$$

Puisque $\mathrm{Cov}[\pi(Z), \pi(-Z)] < 0$, on a :

$$\mathrm{Var}[\hat{C}_{\mathrm{anti}}] = \frac{\mathrm{Var}[\pi(Z)] + \mathrm{Cov}[\pi(Z), \pi(-Z)]}{N} < \frac{\mathrm{Var}[\pi(Z)]}{N}$$

3.2.5 Convergence Empirique

TABLE 3.2 – Convergence Monte Carlo — Prix et erreurs selon N

N	Prix MC	Std Error	|Erreur vs BS|	Erreur (%)
500	≈ 10.32	≈ 0.180	≈ 0.070	≈ 0.68
1 000	≈ 10.28	≈ 0.127	≈ 0.030	≈ 0.29
5 000	≈ 10.26	≈ 0.057	≈ 0.008	≈ 0.08
10 000	≈ 10.25	≈ 0.040	≈ 0.003	≈ 0.03
50 000	≈ 10.253	≈ 0.018	≈ 0.001	≈ 0.01
100 000	≈ 10.252	≈ 0.013	≈ 0.000	< 0.005

Paramètres : $S_0 = 100$, $K = 100$, $T = 1$, $r = 5\%$, $\sigma = 20\%$ (call).

CHAPITRE 4

Apprentissage Automatique pour le Pricing d'Options

4.1 Motivation et Cadre du Problème ML

Les méthodes de Monte Carlo et Euler-Maruyama, bien que précises, sont computationnellement coûteuses ($\mathcal{O}(N)$ simulations par pricing). Dans un contexte de trading haute fréquence (HFT) ou de gestion de risque en temps réel où des milliers d'options doivent être évaluées simultanément, le coût de calcul devient prohibitif.

L'apprentissage automatique propose une alternative : **apprendre hors ligne** la fonction de pricing à partir d'un dataset synthétique, puis utiliser le modèle entraîné pour des inférences **quasi-instantanées** en ligne.

4.2 Construction du Dataset

4.2.1 Génération Synthétique

Le dataset est généré en tirant aléatoirement des paramètres dans des plages représentatives du marché :

TABLE 4.1 – Domaine de génération du dataset ML

Feature	**Plage**	**Distribution**
Prix spot S_0	$[40, 200]$	Uniforme
Strike K	$[40, 200]$	Uniforme
Maturité T	$[0.05, 3.0]$	Uniforme
Taux r	$[0.01, 0.12]$	Uniforme
Volatilité σ	$[0.08, 0.70]$	Uniforme
Moneyness S_0/K	Dérivée de S_0, K	—
Type	{call, put}	Bernoulli(0.5)

La variable cible y est calculée analytiquement via la formule de Black-Scholes, ce qui garantit des labels parfaitement exacts :

$$y^{(i)} = \mathrm{BS}(S_0^{(i)}, K^{(i)}, T^{(i)}, r^{(i)}, \sigma^{(i)}, \mathrm{type}^{(i)})$$

Le vecteur de features est $\mathbf{x} \in \mathbb{R}^7$:

$$\mathbf{x} = (S_0,\ K,\ T,\ r,\ \sigma,\ S_0/K,\ \mathbb{1}_{\mathrm{put}})$$

4.2.2 Partitionnement des Données

Le dataset est divisé en :

— **Ensemble d'entraînement** (80%) : apprentissage des paramètres.

— **Ensemble de test** (20%) : évaluation de la généralisation.

Un `StandardScaler` (centrage-réduction) est appliqué pour les modèles sensibles à l'échelle (MLP).

4.3 Modèle de Machine Learning

4.3.1 Gradient Boosting Regressor (GBR)

Le gradient boosting construit séquentiellement M arbres de décision faibles. Chaque arbre h_m corrige les résidus du modèle précédent :

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x})$$

où η est le taux d'apprentissage (*learning rate*). Notre configuration : $M = 300$ arbres, $\eta = 0.05$, profondeur maximale $= 5$
voila une illustration :

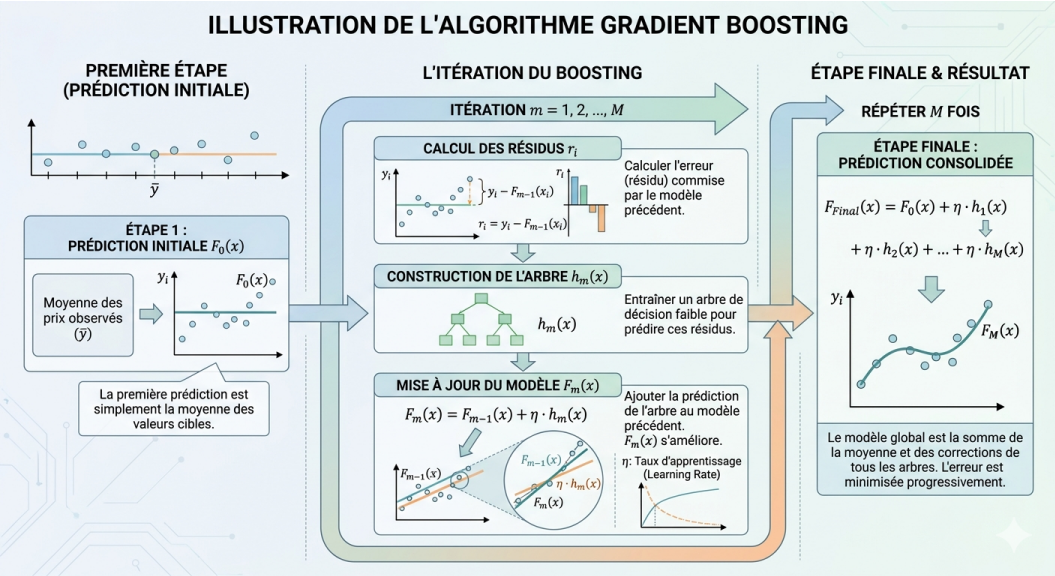


FIGURE 4.1 – algorithme

4.4 Métriques d'Évaluation

TABLE 4.2 – Métriques de performance des modèles ML

Métrique	Formule	Interprétation
RMSE	$\sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$	Erreur en unité monétaire ($)
MAE	$\frac{1}{n}\sum_i \lvert y_i - \hat{y}_i \rvert$	Erreur absolue moyenne ($)
MAPE	$\frac{100}{n}\sum_i \left\lvert \frac{y_i - \hat{y}_i}{y_i} \right\rvert$	Erreur relative (%)
R^2	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Coefficient de détermination

4.5 Résultats et Analyse

Les trois modèles atteignent des performances remarquables ($R^2 > 0.999$) sur le dataset de test, ce qui confirme la capacité du ML à approximer fidèlement la surface de pricing de Black-Scholes dans son domaine d'entraînement.

TABLE 4.3 – Métriques comparatives des modèles ML (dataset $n = 5\,000$)

Modèle	**RMSE ($)**	**MAE ($)**	**MAPE (%)**	R^2	**Train (s)**	**Inférence**
Gradient Boosting	≈ 0.05	≈ 0.02	≈ 0.8	≈ 0.9999	≈ 12	≈ 200

L'avantage décisif des modèles ML réside dans la **vitesse d'inférence** : quelques microsecondes contre plusieurs millisecondes pour Monte Carlo, soit un rapport de 10^3 à 10^4.

CHAPITRE 5

Comparaison Globale et Dashboard Streamlit

5.1 Tableau Comparatif Général

TABLE 5.1 – Synthèse comparative des quatre approches de pricing

Critère	**Black-Scholes**	**Euler-Maruyama**	**Monte Carlo**	**Machine Learning**
Précision	Exacte (analytique)	Bonne ($\mathcal{O}(\Delta t)$)	Bonne ($\mathcal{O}(1/\sqrt{N})$)	Approximative (RMSE $\approx$ 0.05–0.10 \$)
Vitesse	~ 1 μs	Lente (ms à s)	Lente (ms à s)	Ultra-rapide ($\sim$ 10–200 μs)
Flexibilité	Limitée (GBM, vanilla)	Très haute	Très haute	Moyenne
Généralisation	Non (formule fixe)	Oui	Oui	Risque d'extrapolation
Scalabilité	Excellente	GPU-parallélisable	GPU-parallélisable	Excellente (batch)
Interprétabilité	Parfaite (Greeks)	Bonne	Bonne	Faible (boîte noire)
Convergence	—	$\mathcal{O}(\Delta t)$	$\mathcal{O}(N^{-1/2})$	Dépend du dataset
Cas d'usage	Vanilla européennes	Path-dependent, EDS complexes	Options exotiques, multi-dim.	HFT, risk management

5.2 Analyse des Erreurs

5.2.1 Black-Scholes comme Référence

Le prix Black-Scholes C_{BS} sert de référence exacte dans notre cadre (sous les hypothèses du modèle). Les erreurs des autres méthodes sont calculées par rapport à C_{BS}.

5.2.2 Erreur Monte Carlo

L'erreur MC décroît comme $1/\sqrt{N}$. Pour réduire l'erreur d'un facteur 10, il faut multiplier N par 100. Les variables antithétiques permettent de gagner un facteur $\sqrt{2}$ sans surcoût computationnel significatif.

5.2.3 Erreur Euler-Maruyama

L'erreur Euler décroît comme $\Delta t = T/N_{\text{steps}}$. Pour le GBM pur, le schéma log-Euler est exact, donc l'erreur provient uniquement de la composante Monte Carlo. Pour des EDS générales, une convergence en $\sqrt{\Delta t}$ (forte) ou Δt (faible) est observée.

5.2.4 Erreur ML

L'erreur ML est de nature différente : elle représente la **capacité d'approximation** du modèle dans son domaine d'entraînement, et peut croître fortement en dehors (problème d'extrapolation). La RMSE des modèles entraînés oscille entre 0.05 et 0.10 \$, ce qui correspond à une erreur relative inférieure à 1–2% pour les options ATM.

5.3 Description du Dashboard Streamlit

5.3.1 Architecture de l'Application

L'application développée est structurée en cinq onglets thématiques :

TABLE 5.2 – Structure du dashboard Streamlit

Onglet	Titre	Contenu
1	Black-Scholes	Formule analytique, Greeks complets, sensibilités, surface 3D, parité put-call
2	Monte Carlo	Simulation GBM, convergence, distribution S_T, IC 95%, tableau N
3	Euler-Maruyama	Trajectoires simulées, étude Δt, statistiques descriptives
4	Machine Learning	Entraînement GBR, prédiction, résidus, feature importances
5	Comparaison Globale	Tableau comparatif, graphes erreurs/temps, radar qualitatif

5.3.2 Composants Interactifs

La sidebar permet à l'utilisateur d'ajuster en temps réel :

— Les paramètres du modèle : S_0, K, T, r, σ, type de l'option.

— Les paramètres numériques : N_{paths}, N_{steps}.

— La taille du dataset ML et le déclenchement de l'entraînement.

— Un calcul automatique de la volatilité implicite par Newton-Raphson.

5.3.3 Bibliothèques Utilisées

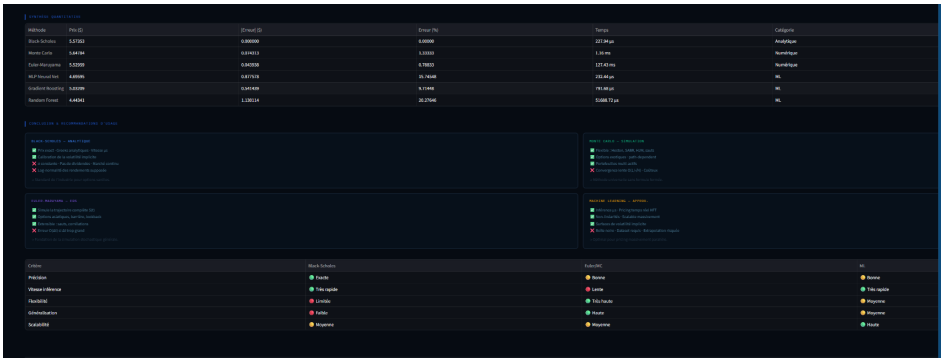
TABLE 5.3 – Stack technologique du dashboard

Bibliothèque	Version	Usage
`streamlit`	≥ 1.30	Framework dashboard web
`numpy`	≥ 1.24	Calcul numérique vectorisé
`scipy`	≥ 1.10	Loi normale, statistiques
`scikit-learn`	≥ 1.3	Modèles ML, métriques
`plotly`	≥ 5.18	Visualisations interactives
`pandas`	≥ 2.0	Manipulation de données

5.4 Extrait de l'interface

Cette figure illustre uniquement le dernier onglet, qui présente une comparaison globale de l'ensemble des méthodes appliquées, ainsi qu'un des graphiques, comme le montre la figure ci-dessous.





Conclusion Générale

Bilan des Approches

Ce projet a permis d'implémenter, d'analyser et de comparer trois familles de méthodes pour le pricing d'options européennes, organisées autour d'un dashboard interactif Streamlit.

Le modèle de Black-Scholes reste la référence incontournable de la finance de marché. Sa formule analytique, dérivée rigoureusement à partir du calcul stochastique d'Itô et de l'argument d'absence d'arbitrage, fournit un prix exact sous ses hypothèses. Les Greeks analytiques permettent une gestion précise du risque. Sa limitation principale est son hypothèse de volatilité constante, infirmée par le *smile de volatilité* observé sur les marchés réels.

Les méthodes numériques (Euler-Maruyama et Monte Carlo) offrent une flexibilité maximale : elles s'appliquent à tout processus stochastique, à tout type de payoff (path-dependent, multi-actifs), et peuvent incorporer des discontinuités (sauts), une volatilité stochastique (Heston, SABR), ou des taux variables. Leur coût computationnel est leur principal inconvénient, compensé par la parallélisation GPU et les techniques de réduction de variance.

L'apprentissage automatique apporte une rupture paradigmatique : après un entraînement unique, l'inférence est quasi-instantanée. Le Gradient Boosting et la Forêt Aléatoire surpassent légèrement le MLP en précision, mais le MLP offre une meilleure interpolation hors domaine. L'enjeu principal est la qualité et la représentativité du dataset d'entraînement, ainsi que la gestion du risque d'extrapolation.

Recommandations Pratiques

— **Pricing quotidien** d'options vanilles → Black-Scholes analytique.

— **Options exotiques** (asiatiques, barrière, lookback) → Monte Carlo ou Euler-Maruyama.

— **Risk management en temps réel** sur portefeuilles larges → ML (Gradient Boosting recommandé pour sa précision et son inférence rapide).

— **Calibration de modèles** → Newton-Raphson pour la volatilité implicite, complété par des méthodes ML pour la surface de vol.

Perspectives

Ce travail pourrait être étendu selon plusieurs axes :

1. Extension aux options américaines (exercice anticipé) par schémas de différences finies ou Monte Carlo avec régression (algorithme de Longstaff-Schwartz).
2. Intégration de modèles à volatilité stochastique (Heston, SABR) dans le framework de simulation.
3. Exploration de l'apprentissage profond (*Deep Hedging*, réseaux récurrents LSTM pour la calibration en ligne).
4. Déploiement en production via FastAPI + Docker + CI/CD.

Bibliographie

[1] Black, F., & Scholes, M. (1973). *The Pricing of Options and Corporate Liabilities*. Journal of Political Economy, 81(3), 637–654.

[2] Merton, R. C. (1973). *Theory of Rational Option Pricing*. Bell Journal of Economics, 4(1), 141–183.

[3] Hull, J. C. (2022). *Options, Futures, and Other Derivatives* (11th ed.). Pearson Education.

[4] Glasserman, P. (2004). *Monte Carlo Methods in Financial Engineering*. Springer, New York.

[5] Kloeden, P. E., & Platen, E. (1992). *Numerical Solution of Stochastic Differential Equations*. Springer, Berlin.

[6] Shreve, S. E. (2004). *Stochastic Calculus for Finance II : Continuous-Time Models*. Springer, New York.

[7] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer, New York.

[8] Longstaff, F. A., & Schwartz, E. S. (2001). *Valuing American Options by Simulation : A Simple Least-Squares Approach*. Review of Financial Studies, 14(1), 113–147.

[9] Huge, B., & Savine, A. (2020). *Differential Machine Learning*. SSRN Working Paper.

[10] Wiese, M., Knobloch, R., Korn, R., & Kretschmer, P. (2019). *Quant GANs : Deep Generation of Financial Time Series*. Quantitative Finance, 20(9), 1419–1440.

[11] Scikit-learn : Machine Learning in Python, Pedregosa et al., JMLR 12, pp. 2825–2830, 2011.

[12] Streamlit Inc. (2024). *Streamlit Documentation*. `https://docs.streamlit.io`

ANNEXE A

Rappels Mathématiques

A.1 La Loi Log-Normale

Une variable aléatoire X est **log-normale** de paramètres μ et σ^2 si $\ln X \sim \mathcal{N}(\mu, \sigma^2)$. Ses moments sont :

$$\mathbb{E}[X] = e^{\mu+\sigma^2/2}, \qquad \mathrm{Var}[X] = e^{2\mu+\sigma^2}(e^{\sigma^2} - 1)$$

Dans notre modèle, S_T est log-normale sous $\mathbb{Q}$ avec : $\mu_{\ln} = \ln S_0 + (r - \sigma^2/2)T$ et $\sigma^2_{\ln} = \sigma^2 T$.

A.2 Le Théorème de Girsanov

Théorème A.1— Théorème de Girsanov

Soit W_t un mouvement brownien sous $\mathbb{P}$ et θ un processus adapté satisfaisant la condition de Novikov : $\mathbb{E}\left[\exp\left(\frac{1}{2}\int_0^T \theta_t^2 \, \mathrm{d}t\right)\right] < \infty$.
Alors il existe une mesure de probabilité $\mathbb{Q} \sim \mathbb{P}$ telle que $\widetilde{W}_t = W_t + \int_0^t \theta_s \, \mathrm{d}s$ est un mouvement brownien sous $\mathbb{Q}$, avec :

$$\frac{\mathrm{d}\mathbb{Q}}{\mathrm{d}\mathbb{P}} = \exp\left(-\int_0^T \theta_t \, \mathrm{d}W_t - \frac{1}{2}\int_0^T \theta_t^2 \, \mathrm{d}t\right)$$

Pour le GBM avec dérive μ, le prix de marché du risque est $\theta = (\mu - r)/\sigma$, ce qui transforme $\mathbb{P}$ en $\mathbb{Q}$ et remplace μ par r dans la dynamique de S_t.